LAPORAN LENGKAP PROYEK · GUIDED PROJECT · OKTOBER 2026 · EDISI V2 — OKTOBER 2026

Fraud Triage
Konsol Triase Smishing

Edisi v2 — Oktober 2026. Seluruh isi edisi pertama dipertahankan utuh. Edisi ini menambahkan satu bagian besar baru di akhir laporan: Bagian 12 — Siskamling Digital, perjalanan konsol riset ini menjadi layanan publik lapor & cek smishing (Fase 0 sampai v5.9.1).

Sistem triase SMS penipuan (smishing) berbasis **ensemble machine learning terkalibrasi** dan **lapisan aturan deterministik** — dibangun sebagai proyek pembelajaran terpimpin, dan dievaluasi dengan gerbang klaim yang dikunci *sebelum* hasil diketahui.

Vonis akhir, apa adanya: klaim "9/10" untuk pesan Indonesia GAGAL 2 dari 4 gerbang di Tahap 2D. Model aplikasi tidak ditukar — kegagalan itu didokumentasikan lengkap di laporan ini, karena rigor evaluasinya adalah nilai proyek ini.

PR-AUC TEST (INGGRIS)	SAH INDONESIA TERBAIK	SMISHING TAHAP 2D	AUTO-CLOSE SMISHING
0,986	**92,7%**	**88,7%**	**2**
Ensemble Top-3 Terkalibrasi pada data UCI — gerbang ≥ 0,98 **LOLOS**	Tahap 2D, naik dari baseline 16,0% — gerbang ≥ 85% **LOLOS**	Mundur dari 94,7% (2C) — gerbang ≥ 95% **GAGAL**	Tahap 2D — gerbang = 0 **GAGAL**

Isi laporan

1. Ringkasan eksekutif · 2. Modelnya apa saja · 3. Arena benchmark · 4. Datanya · 5. Tahapan & perlakuan · 6. Hasil · 7. Evaluasi · 8. Riset dataset Indonesia · 9. Pemanfaatan & penerapan · 10. Batasan · 11. Situs & fitur aplikasi · **12. Siskamling Digital (baru di Edisi v2)** · Tautan

Tautan utama

Demo live: https://fraud-triage-demo.streamlit.app/
Kode sumber: https://github.com/rwnliwan/fraud-triage
Model: https://huggingface.co/rwnliwan/fraud-triage-smishing

Seluruh angka di laporan ini diambil dari berkas evaluasi terverifikasi proyek (*results.json* yang dibangkitkan dari file evaluasi, bukan diketik manual). Istilah teknis dipertahankan dalam Bahasa Inggris; narasi dalam Bahasa Indonesia.

BAGIAN 1

1. Ringkasan Eksekutif

Masalahnya sederhana dan mahal: banjir SMS penipuan (smishing) harus diurutkan untuk analis manusia — pesan paling berbahaya diperiksa duluan, pesan sah tidak ikut terseret. Fraud Triage menjawabnya dengan skor risiko terkalibrasi yang mengurutkan antrean, bukan memvonis.

Pendekatan. Tiga model yang berbeda sifat digabung menjadi satu ensemble: DistilBERT multilingual hasil fine-tune (memahami konteks bahasa), TF-IDF + Fitur Angka + Logistic Regression (menangkap pola permukaan seperti tautan, angka, dan urgensi), dan TF-IDF + Logistic Regression (baseline teks murni). Skor ketiganya dikalibrasi dengan *temperature scaling* lalu dirata-rata, dan dipetakan ke tiga band operasional lewat dua ambang: di bawah **t_close = 0,010** pesan ditutup otomatis (AUTO-CLOSE), di atas **t_esc = 0,135** pesan dieskalasi, di antaranya masuk REVIEW ANALIS. Di atas model, lapisan aturan deterministik hanya boleh *menaikkan* band pada kombinasi sinyal paling berbahaya.

Temuan inti. Model ini sangat kuat pada bahasa Inggris — PR-AUC 0,986 pada set tes UCI. Tetapi ketika diuji pada 300 pesan Indonesia yang tidak pernah menjadi data latih (set hakim), hanya **16,0% pesan sah** yang lolos: 84% pesan resmi Indonesia dieskalasi. Diagnosisnya bukan model yang lemah, melainkan *register*: pesan formal-institusional Indonesia tidak pernah ada di data latih Inggris sekitar 2011, sehingga pesan yang “terdengar resmi” justru terbaca mencurigakan — median skor pesan sah (0,471) bahkan lebih tinggi daripada median skor smishing (0,402).

Perjalanan perbaikan. Enam tahap dijalankan: baseline (0), sinyal penenang berbasis aturan (1), pembangunan korpus Indonesia (2A), fine-tune dwibahasa (2B), perakitan paket dwibahasa (2C), dan satu loop perbaikan terukur (2D). SAH naik 16,0% → 36,0% → 84,0% → **92,7%**. Namun Tahap 2D menukar masalah: SMISHING mundur ke 88,7% dan 2 smishing tetap lolos ke zona AUTO-CLOSE.

Vonis Tahap 2D: DITOLAK — 2 dari 4 gerbang.

SAH 92,7% **lolos** · PR-AUC UCI 0,9882 **lolos** · SMISHING 88,7% **gagal** · AUTO-CLOSE 2 **gagal**. Sesuai doktrin yang dikunci di muka — satu loop perbaikan, lalu dokumentasikan apa adanya — penalaan dihentikan dan **model aplikasi tidak ditukar**: model live tetap ensemble CHOSEN + aturan Tahap 1.

Pelajaran terbesar justru struktural. Riset ketersediaan data membuktikan dataset smishing Bahasa Indonesia yang publik memang belum ada (lihat Bagian 8). Bottleneck proyek ini bukan algoritma — melainkan ketiadaan korpus Indonesia modern berlabel.

BAGIAN 2

2. Modelnya Apa Saja

Sistem yang berjalan di aplikasi adalah **Ensemble Top-3 Terkalibrasi (CHOSEN)** — pemenang arena benchmark Bagian 3 — ditambah dua lapisan non-ML di atasnya: aturan keamanan dan sinyal penenang.

Anggota ensemble

Anggota	Sifat	Temperatur kalibrasi
DistilBERT multilingual (fine-tune pada UCI)	Model bahasa kontekstual; membaca makna dan register teks dwibahasa	1,184
TF-IDF + Fitur Angka + Logistic Regression	Kata-kata kunci + fitur permukaan (tautan, digit, nominal, panjang pesan)	0,926
TF-IDF + Logistic Regression	Baseline teks murni; cepat dan stabil	0,614

Kalibrasi: skor mentah tiap anggota dilunakkan dengan *temperature scaling* (temperatur ensemble 1,0 by design), lalu dirata-rata menjadi **P(scam) terkalibrasi** — angka yang bisa dibaca sebagai proporsi: skor 0,42 berarti kira-kira 42 dari 100 pesan serupa ternyata smishing. Mesin berjalan **fp32** di CPU (uji float16 ditolak: latensi memburuk +56%).
Kebijakan dua ambang: t_close = 0,010 (sengaja sangat rendah — smishing hampir mustahil ikut tertutup) dan t_esc = 0,135.

Lapisan aturan — hanya menaikkan (rules.py, regex murni)

Aturan terpicu hanya bila **≥ 2 dari 3 sinyal kuat** hadir bersamaan; bila terpicu, band final dipaksa ke ESKALASI berapa pun skor modelnya. Aturan tidak pernah menurunkan band dan tidak mengubah skor.

Kode	Sinyal
S1	Ada tautan (URL) dalam pesan — terutama pemendek tautan atau domain tak resmi
S2	Permintaan memasukkan OTP/PIN/kredensial, atau bertindak lewat tautan
S3	Ancaman blokir/suspensi/hangus *disertai* urgensi waktu (keduanya wajib hadir)

Pelindung pesan sah: kalimat khas bank “JANGAN bagikan kode ini kepada siapa pun” secara eksplisit **bukan** sinyal S2 — kata kerja meminta-masukkan tidak mencakup “berikan/bagikan”, dan kecocokan yang didahului “jangan” dibuang.

Sinyal penenang — arah sebaliknya, sama ketatnya (Tahap 1)

Kode	Pola resmi yang dikenali
P1	Format OTP standar: kode + frasa penjaga “jangan bagikan”, tanpa tautan sama sekali
P2	Seluruh tautan ber-host *persis* domain resmi terkurasi (17 domain bank/telco/kurir/e-commerce Indonesia; domain siluman seperti *bca.co.id.evil.com* tidak lolos)
P3	Notifikasi transaksi terstruktur tanpa tautan: nominal Rp + penanda pernyataan (saldo / nomor referensi / “berhasil” transaksional), gugur bila ada umpan hadiah

Mekanik keras penenang: hanya bekerja pada band model ESKALASI, menurunkan **tepat satu tingkat** ke REVIEW ANALIS, tidak pernah menghasilkan AUTO-CLOSE, tidak mengubah skor, dan **gugur total** bila sinyal kuat S2/S3 aktif atau aturan keamanan terpicu — arah naik selalu menang.

BAGIAN 3

3. Arena Benchmark — Bagaimana Model Dipilih

Sebelum ensemble ditetapkan, enam kandidat diadu pada set tes yang sama (data Inggris UCI). Tiga metrik dibaca bersamaan, karena satu angka saja menipu: model bisa tajam membedakan (PR-AUC tinggi) tetapi skornya tidak jujur (ECE tinggi), atau aman di rata-rata tetapi melewatkan terlalu banyak smishing saat alarm palsu dibatasi (Recall@FPR1% rendah).

Kandidat	PR-AUC	Recall@FPR1%	ECE	Status
Ensemble (Top-3 Terkalibrasi)	0,986	0,947	0,026	CHOSEN
DistilBERT multilingual (fine-tune)	0,985	0,947	0,010	Anggota ensemble
TF-IDF + Fitur Angka + Logistic Regression	0,980	0,924	0,009	Anggota ensemble
TF-IDF + Naive Bayes	0,970	0,916	0,013	Gugur
TF-IDF + Logistic Regression	0,959	0,893	0,039	Anggota ensemble*
TF-IDF + Gradient Boosting	0,933	0,863	0,010	Gugur

*Versi TF-IDF + Logistic Regression di dalam ensemble adalah anggota yang dilatih dalam resep ensemble (Bagian 9 notebook); angka arena di atas adalah kandidat mandirinya. Kandidat lain yang diuji di luar arena kartu app: **Laya** (fine-tune alternatif) mencapai PR-AUC 0,982 tetapi **gugur** — ECE 0,094 (skornya tidak cukup jujur untuk perangkingan triase) dan latensi 2,81 detik/pesan; posisinya dicatat sebagai kandidat lapisan teks, bukan model operasional.

Cara membaca tiga metrik ini

PR-AUC — ketajaman membedakan smishing dari pesan sah di seluruh titik ambang; makin mendekati 1 makin baik. Ini metrik utama karena kelasnya tidak seimbang.
Recall@FPR1% — berapa persen smishing tertangkap ketika alarm palsu dibatasi hanya 1%: metrik “dunia nyata”, karena analis tidak bisa memeriksa semua pesan.
ECE (Expected Calibration Error) — selisih kejujuran skor terhadap kenyataan; makin kecil makin baik. Skor triase yang tidak jujur meracuni urutan antrean.

Ensemble menang bukan karena satu metrik, melainkan karena kombinasi: PR-AUC tertinggi, recall setara anggota terbaiknya, dan ECE yang cukup rendah setelah kalibrasi — dengan tiga sifat model yang saling menambal kelemahan (konteks bahasa, pola permukaan, baseline teks).

BAGIAN 4

4. Datanya

Data latih utama — UCI SMS Spam Collection

Koleksi SMS Bahasa Inggris dari sekitar tahun 2011. Di sinilah model operasional belajar — dan di sinilah akar masalahnya: tidak ada satu pun pesan resmi institusi Indonesia di dalamnya. Seluruh perjalanan Tahap 2 adalah upaya menambal lubang data ini tanpa mengorbankan kemampuan Inggrisnya (yang dijaga gerbang PR-AUC ≥ 0,98).

Korpus Indonesia Tahap 2A — dibangun dari nol (2.512 baris)

Sumber	Baris lolos	Catatan & lisensi
Publik: Kaggle *gevabriel/indonesian-sms-spam*	1.096	CC0; keturunan korpus GitHub agtbaskara (SMS Indonesia ±2012–2016). Label 3-kelasnya (penipuan / promo / normal) dipulihkan lewat Kaggle *crystalbaby* (Apache 2.0), lalu dipetakan: penipuan → 1, promo → 1, normal → 0
Generate: 25 keluarga templat	1.416	12 keluarga sah / 13 keluarga smishing, ditulis menargetkan wilayah lemah Tahap 1; institusi & domain fiktif yang berbeda dari set evaluasi
Total korpus 2A	**2.512**	Hampir seimbang: 1.255 positif / 1.257 negatif; 0 duplikat; QA baca acak 30/30 wajar

Gerbang anti-bocor 3 lapis terhadap set hakim: (1) teks persis sama dibuang, (2) kerangka sama — digit & domain ditopeng — dibuang, (3) kemiripan Jaccard token ≥ 0,80 dibuang. Dari 1.143 baris publik: dibuang 15 persis + 11 kerangka + 20 Jaccard + 1 duplikat. Jaccard maksimum yang lolos: 0,793 (baris publik) dan 0,55 (baris templat).

Data Tahap 2D — tambahan terarah (980 baris)

980 baris baru dari 7 keluarga templat, ditulis dari nol menargetkan tiga kategori terlemah 2C — dipilih dari *pola kategori*, bukan menyalin set hakim. 600 baris masuk FIT; 380 baris dari 3 keluarga ditahan utuh untuk kalibrasi. Gerbang kemiripan: Jaccard maksimum yang lolos vs set hakim 0,50.

Set penilaian — tidak pernah menjadi data latih

Set	Isi	Fungsi
Set hakim	300 pesan Indonesia berlabel: 150 SAH / 150 SMISHING, 20 kategori	Satu-satunya hakim gerbang klaim; tidak pernah dipakai melatih model mana pun
Panel transparansi	16 pesan buatan (8 sah / 8 smishing, bank fiktif “Bank Nusantara” / “Bank Sentosa”), dikunci di kode sebelum pertama kali dijalankan	Panel jendela di app — *bukan* benchmark
Split FIT / KALIBRASI	2B–2C: FIT 5.831 / KALIBRASI 816 · 2D: FIT 6.431 / KALIBRASI 1.196	FIT melatih model; KALIBRASI menurunkan temperatur & ambang — keduanya terpisah dari set hakim

BAGIAN 5

5. Tahapan & Perlakuan

Enam tahap, satu alur: empat tahap berkunci gerbang (0, 1, 2C, 2D) dan dua tahap persiapan tanpa skor gerbang (2A data, 2B model). Setiap tahap mengubah tepat satu lapisan yang terukur, supaya penyebab setiap perubahan angka bisa ditunjuk.

0
22 Okt 2026

Baseline & diagnosis BASELINE

Perlakuan: tidak ada — model live dinilai apa adanya sebagai titik berangkat. **Model:** Ensemble Top-3 Terkalibrasi CHOSEN (t_close 0,010 · t_esc 0,135). **Data:** latih UCI Inggris ±2011; nilai pada set hakim 300.

1
22 Okt 2026

Sinyal penenang (aturan) DITERIMA — app v4

Perlakuan: model **tidak diubah sama sekali**; hanya lapisan aturan ditambah sinyal penenang satu arah (turun tepat satu tingkat, bersyarat ketat, gugur bila ada sinyal kuat). **Data:** tidak ada data latih baru; paket dinilai ulang pada set hakim yang sama.

2A
22 Okt 2026

Korpus latih Indonesia TAHAP DATA

Perlakuan: membangun **data** latih Indonesia dari nol — belum ada model baru. Kumpulkan, pulihkan label, buat keluarga templat, saring gerbang anti-bocor 3 lapis, samarkan. **Hasil:** korpus 2.512 baris lolos semua gerbang.

2B
22 Okt 2026

Fine-tune DistilBERT dwibahasa TAHAP MODEL

Perlakuan: melatih **model** bahasa dwibahasa di GPU Colab T4: *distilbert-base-multilingual-cased*, klasifikasi biner, max_len 64, batch 16, AdamW lr 5e-5, 2 epoch, seed 42. **Data:** FIT 5.831 (UCI 3.722 + korpus 2A) / KALIBRASI 816. Ambang & penilaian gerbang belum terjadi di tahap ini.

2C
22 Okt 2026

Perakitan & penilaian paket dwibahasa DITOLAK

Perlakuan: merakit 2A + 2B menjadi paket kandidat utuh: BERT fine-tune (temperatur 2,0129) + dua anggota sklearn dilatih ulang + ambang diturunkan ulang dari kalibrasi (t_close 0,2930 · t_esc 0,3516), lalu dinilai *full-stack*. **Model:** ensemble dwibahasa **baru**, bukan model live.

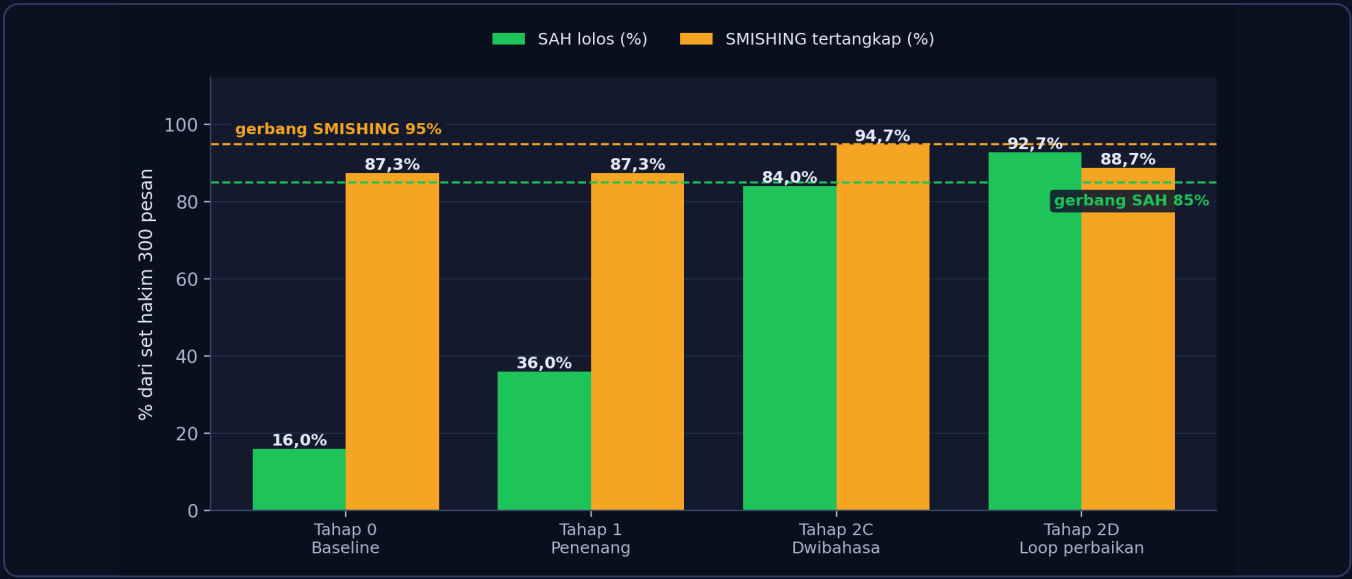
2D
23 Okt 2026

Loop perbaikan 2D DITOLAK — 2/4 GERBANG

Perlakuan: satu loop terukur dari 2C: +980 baris tepat pada kategori terlemah + kriteria derivasi t_close diganti **toleransi-nol** + aturan pemilihan epoch ditetapkan di muka; arsitektur tidak berubah. **Model:** dilatih ulang dari awal; checkpoint epoch-1 menang (PR-AUC kalibrasi 0,9673 vs 0,9288). Ambang baru: t_close 0,1422 · t_esc 0,4092. **Data:** FIT 6.431 / KALIBRASI 1.196.

BAGIAN 6

6. Hasil — Angka per Tahap



SAH lolos dan SMISHING tertangkap pada set hakim 300 pesan, empat tahap berkunci gerbang. Garis putus-putus = gerbang klaim yang dikunci di muka (SAH ≥ 85%, SMISHING ≥ 95%).

Tahap	SAH %	SMISHING %	Total %	AUTO-CLOSE	PR-AUC UCI	Panel 16	Vonis
0 Baseline	16,0	87,3	51,7	0	0,9860	1/8 · 8/8	Baseline
1 Penenang	36,0	87,3	61,7	0	0,9864	3/8 · 8/8	Diterima (app v4)
2C Dwibahasa	84,0	94,7	89,3	**3**	0,9862	7/8 · 8/8	**Ditolak** — gagal tipis
2D Loop perbaikan	**92,7**	**88,7**	90,7	**2**	**0,9882**	8/8 · 8/8	**Ditolak** — 2/4 gerbang

Panel 16 dibaca: pesan sah yang sesuai · smishing yang sesuai, dari 8 + 8 pesan panel transparansi. Angka persiapan: **2A** menghasilkan korpus 2.512 baris lolos gerbang anti-bocor; **2B** fine-tune selesai ±90 detik/epoch dengan PR-AUC kalibrasi mentah epoch 1 = 0,9746 dan epoch 2 = 0,9115 (overfit terdeteksi).

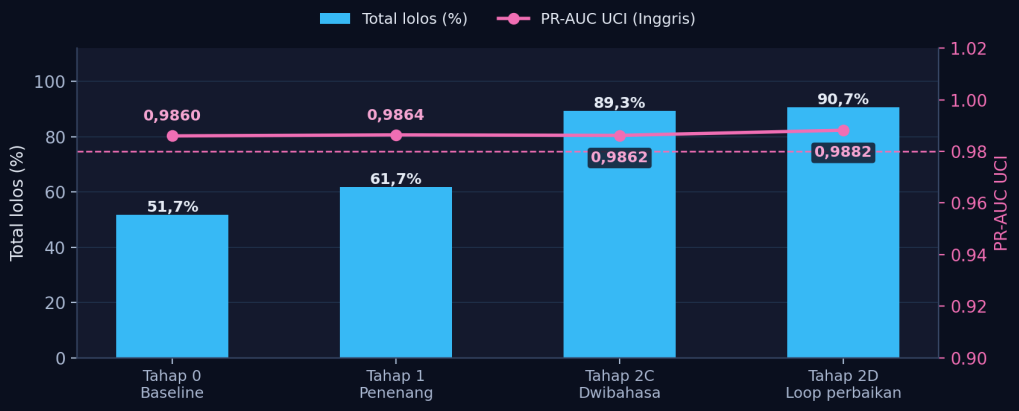
Membaca perjalanan angkanya

Tahap 0 → 1: SAH naik 16,0% → 36,0% dengan SMISHING dan AUTO-CLOSE tidak bergerak sama sekali — penenang 0× salah tembak. Tambal aturan terbukti aman, tetapi plafonnya rendah. **Tahap 2C:** lompatan besar (SAH 84,0%, SMISHING 94,7%), tetapi 3 smishing masuk AUTO-CLOSE — satu-satunya regresi keamanan — karena t_close turunan kalibrasi (0,2930) jauh lebih longgar daripada t_close app lama (0,010). Gagalnya tipis: SAH kurang 2 pesan, SMISHING kurang 1 pesan. **Tahap 2D:** kategori target sembuh (keamanan bank resmi 60,0% → 93,3%; APK malware 73,3% → 100%) dan panel 16 sempurna 16/16 untuk pertama kalinya — tetapi SMISHING mundur dan AUTO-CLOSE belum nol.

BAGIAN 6 — LANJUTAN

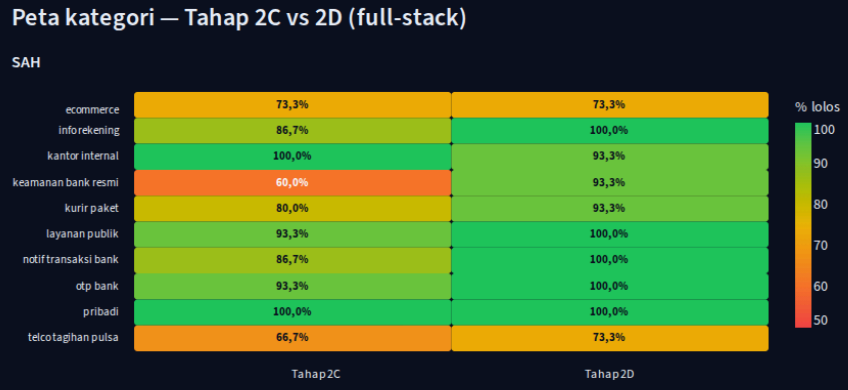
Gerbang Klaim di Tahap 2D — Vonis Final

SAH ≥ 85%	SMISHING ≥ 95%	AUTO-CLOSE = 0	PR-AUC ≥ 0,98
92,7%	**88,7%**	**2**	**0,9882**
LOLOS — kategori target sembuh	GAGAL — kurang 9 pesan	GAGAL — celah generalisasi kalibrasi	LOLOS — tertinggi sejauh ini



Total lolos (batang) dan PR-AUC UCI (garis) per tahap. Kemampuan Inggris tidak pernah dikorbankan di semua tahap — PR-AUC selalu di atas gerbang 0,98, dan mencapai titik tertinggi di 2D.

Kenapa SMISHING mundur di 2D? Dua mekanisme terukur: (1) 300 baris SAH formal baru menekan skor smishing non-target (model-saja 94,7% → 88,0%); (2) t_esc naik 0,3516 → 0,4092 sehingga 15 smishing berhenti di REVIEW alih-alih ESKALASI. Kriteria toleransi-nol terpenuhi di kalibrasi, tetapi 2 smishing set hakim tetap lolos ke bawah t_close — celah generalisasi, karena 52% kalibrasi adalah keluarga templat penahan. Harga lainnya: pesan SAH yang berhenti di REVIEW naik 23 → 47 — beban analis naik. Tidak ada satu pun angka yang digeser sesudah melihat set hakim.



Heatmap per kategori di tab Perjalanan Riset aplikasi: keamanan bank resmi sembuh (60,0% → 93,3%) dan APK malware tuntas (100%), sementara beberapa kategori smishing non-target mundur — persis pertukaran masalah yang tercatat di vonis 2D.

BAGIAN 7

7. Evaluasi — Gerbang yang Dikunci di Muka

Klaim “9/10” proyek ini tidak dinilai dengan perasaan. Sebelum satu pun hasil Indonesia dilihat, empat gerbang ditetapkan dan dikunci:

Gerbang	Ambang	Alasan
SAH lolos	≥ 85%	Pesan sah yang dieskalasi adalah biaya operasional langsung bagi analis
SMISHING tertangkap	≥ 95%	Klaim 9/10 menuntut deteksi nyaris tuntas pada pesan berbahaya
SMISHING masuk AUTO-CLOSE	= 0	Gerbang keamanan absolut: satu pun smishing yang ditutup otomatis = paket tidak aman
PR-AUC UCI (Inggris)	≥ 0,98	Perbaikan Indonesia tidak boleh dibayar dengan kemunduran kemampuan Inggris

Definisi *full-stack*: yang dinilai gerbang adalah paket utuh — model + lapisan aturan + sinyal penenang, persis konfigurasi aplikasi live — bukan skor model mentah. Angka model-saja boleh dilaporkan sebagai diagnosis, tetapi tidak pernah dipakai mengklaim gerbang.

Disiplin hakim: set hakim 300 pesan tidak pernah menjadi data latih model mana pun, dan tidak ada angka yang digeser sesudah melihatnya. Data perbaikan 2D dipilih dari pola kategori terlemah, ditulis dari nol, dan disaring terhadap set hakim — menala ke arah set hakim yang sudah diamati berulang adalah overfitting, dan itulah salah satu alasan penalaan dihentikan sesudah satu loop.

Panel 16 di aplikasi adalah panel transparansi, bukan benchmark: 16 pesan buatan berlabel harapan (bank fiktif) yang dikunci di kode sebelum pertama kali dijalankan, ditampilkan apa adanya — termasuk kegagalannya (SAH hanya 1/8 pada model baseline). **Simulator ambang** di tab yang sama menghitung ulang dampak t_close/t_esc terhadap panel secara langsung, tanpa mengubah ambang live aplikasi.

BAGIAN 8

8. Riset Dataset Indonesia — Bottleneck Struktural

Temuan riset (Oktober 2026): dataset smishing Bahasa Indonesia yang publik = nol.

Satu-satunya korpus SMS Indonesia asli yang publik adalah korpus 3-kelas berisi **1.143 baris** dari era **2013–2015** (yang dipakai Tahap 2A lewat gevabriel/agtbaskara) — kecil, tua, dan labelnya bukan biner smishing. Modus modern yang justru paling merugikan hari ini — APK penipuan via WhatsApp, pinjol ilegal, judi online — tidak memiliki contoh berlabel publik sama sekali.

Konsekuensinya jujur: korpus latih Indonesia harus sebagian besar *dibuat sendiri* (keluarga templat), dan templat membawa risiko artefak. Kegagalan klaim Indonesia di proyek ini karena itu dibaca sebagai temuan tentang ketersediaan data, bukan sekadar kegagalan model — dan menutup celahnya adalah pekerjaan pengumpulan data, bukan penalaan tanpa henti.

BAGIAN 9

9. Pemanfaatan & Penerapan

Yang bisa dipakai hari ini adalah **polanya**: *mesin mengurutkan, manusia memutuskan.* Skor terkalibrasi mengurutkan antrean, lapisan aturan menjaga kasus paling berbahaya, dan manusia tetap pemegang vonis.

Bisa diterapkan di mana

- **Antrean triase bank & fintech** — perangkingan prioritas laporan SMS/pesan mencurigakan untuk analis fraud
- **Operasi CS e-wallet & telco** — penyaringan awal banjir laporan pesan mencurigakan
- **Pusat pengaduan** — filter awal sebelum penelaahan manusia
- **Artefak pembelajaran & portofolio** — contoh utuh pipeline ensemble terkalibrasi + gerbang klaim yang dikunci di muka

Syarat naik ke produksi

- Korpus smishing Indonesia **segar dan berlabel** — bukan templat
- Latih ulang + **kalibrasi ulang** ambang pada data itu
- **Human-in-the-loop permanen** — skor tetap perangkingan, bukan vonis
- Pemantauan **drift**: modus penipuan berubah lebih cepat daripada model
- Tata kelola data pribadi: isi pesan pengguna adalah data sensitif

Bisa tidak diaplikasikan? Jawaban jujurnya: bobot modelnya belum siap produksi. Klaim Indonesianya gagal 2 dari 4 gerbang dan data latih utamanya SMS Inggris ±2011. Memasang bobot ini mentah-mentah di sistem perbankan akan mengeskalasi sebagian besar pesan sah pelanggan — persis penyakit yang terukur di Tahap 0.

BAGIAN 10

10. Batasan

- **Data latih tua & berbahasa Inggris.** UCI ±2011 tidak memuat register resmi Indonesia maupun modus smishing modern; pola Indonesia modern berada di luar distribusi itu.
- **Risiko artefak templat.** 1.258 pasangan sekeluarga di korpus templat hanya berbeda digit/domain tertopeng — model bisa belajar jalan pintas templat, bukan register.
- **Celah generalisasi kalibrasi.** Kriteria toleransi-nol 2D terpenuhi di split kalibrasi (52%-nya keluarga templat penahan), tetapi 2 smishing set hakim tetap lolos ke bawah t_close.
- **Beban REVIEW naik.** Di 2D, pesan SAH yang berhenti di REVIEW naik 23 → 47 — perbaikan SAH dibayar dengan antrean analis yang lebih panjang.
- **Overfit epoch terdeteksi.** Fine-tune dwibahasa overfit sejak epoch 2 (PR-AUC kalibrasi 0,9746 → 0,9115); pemilihan epoch harus diatur di muka.
- **Bukan sistem produksi bank.** Ini artefak proyek pembelajaran terpimpin: tanpa penyimpanan permanen, log koreksi hanya hidup di sesi browser, dan tidak ada SLA inferensi.

BAGIAN 11

11. Situs & Fitur Aplikasi (v5.4.0)

Aplikasi Streamlit bertema gelap “fraud ops console” menyajikan model terpilih dalam empat tab, dengan sidebar ringkas: kartu status model (CHOSEN, t_close, t_esc, PR-AUC, mesin fp32 — masing-masing ditemani ikon “?” ber-tooltip), peringatan keterbatasan terpenting, dan dropdown “Lihat detail” berisi lima topik: komposisi model, aturan & penenang, keterbatasan lengkap, benchmark arena, dan tautan.

Analisis Tunggal

- Contoh pesan siap-klik (termasuk OTP bank asli) — klik langsung menganalisis
- Kartu vonis berwarna + kalimat penjelasan + bilah skor terhadap kedua ambang
- Panel sinyal teks S1–S3 & penenang, dengan lencana pemicu yang transparan
- Skor per anggota ensemble (mentah & temperatur), faktor teks pendorong skor
- Tombol koreksi pengguna + log koreksi sesi, riwayat sesi, ekspor CSV
- Batas input 2.000 karakter dengan peringatan pemotongan

Evaluasi ID

- Panel transparansi 16 pesan berlabel harapan, dijalankan apa adanya
- Simulator ambang interaktif: geser t_close/t_esc, dampaknya terlihat langsung — ambang live tidak berubah

Mode Batch

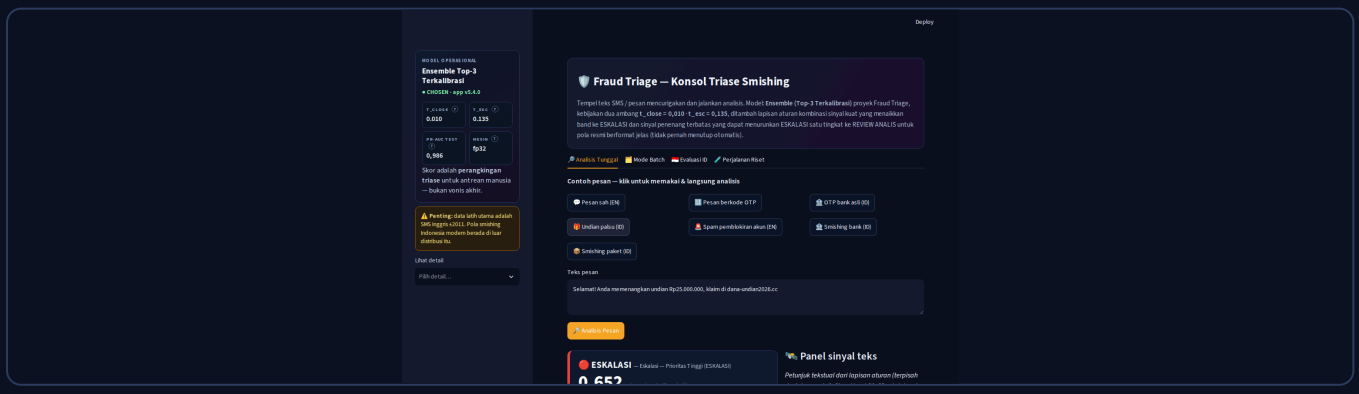
- Satu pesan per baris, batas 200 baris, bilah progres per pesan
- Hasil sebagai **antrean prioritas** terurut skor tertinggi — cara analis menatap antrean triase sesungguhnya
- Pemilih detail per kasus: teks penuh, skor, band model vs final, sinyal aturan & penenang
- Unduh **laporan per kasus** (.md) dan ekspor CSV hasil batch

Perjalanan Riset

- Kronik enam tahap 0 → 2D dengan diagram gerbang dan vonis apa adanya
- Detail per tahap: Perlakuan / Model / Data & sumber / Hasil / Pelajaran
- Heatmap kategori dua chart terpisah (SAH dan SMISHING) yang melebar penuh

Di semua tab

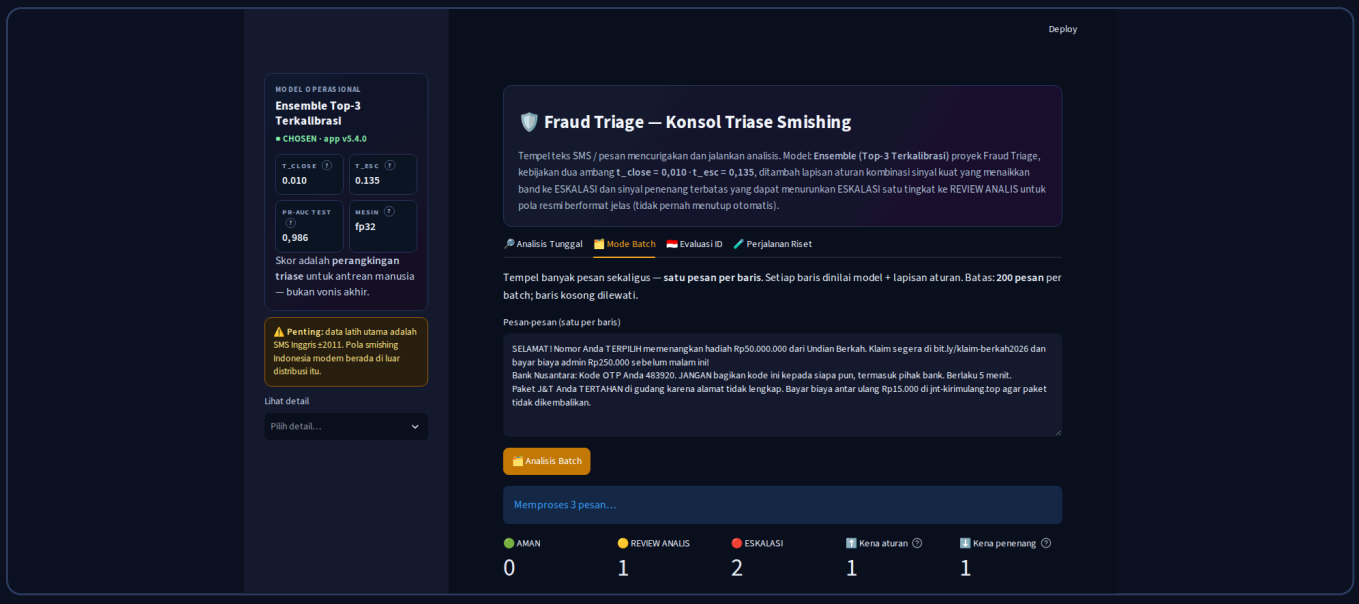
- CSS responsif mode phone (media query ≤640px / ≤480px): padding dikencangkan, chart selebar kontainer
- Ikon “?” pada label jargon: hover di desktop, tap di HP



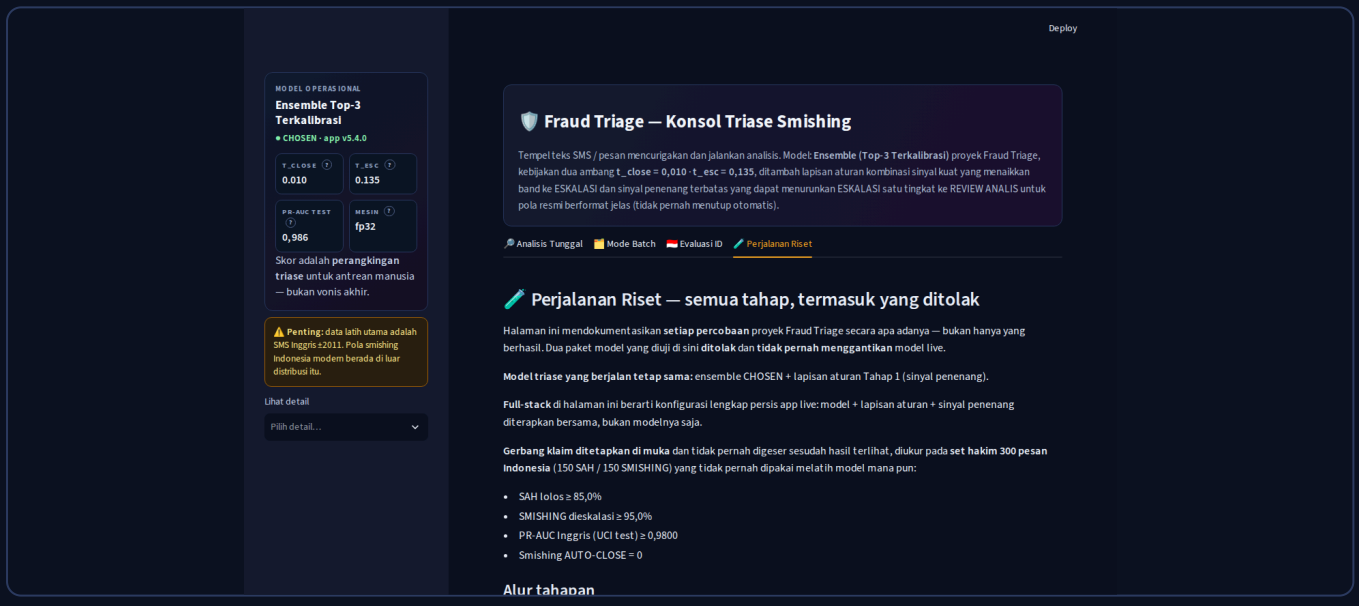
Tab Analisis Tunggal (v5.4.0): sidebar kartu status model dengan ikon “?”, contoh pesan siap-klik, dan kartu hasil ESKALASI untuk contoh smishing undian palsu.

GALERI APLIKASI

App dalam Gambar



Mode Batch: tiga pesan dinilai sekaligus dan ringkasan band tampil langsung (AMAN 0 · REVIEW ANALIS 1 · ESKALASI 2), lengkap dengan hitungan “Kena aturan” dan “Kena penenang” — hasil lengkapnya tersaji sebagai antrean prioritas dengan laporan per kasus.



Tab Perjalanan Riset: alur enam tahap dengan vonis singkat per tahap, diagram skor gerbang, dan detail Perlakuan / Model / Data untuk setiap tahap.

BAGIAN 12 — BARU DI EDISI V2

12. Siskamling Digital — Dari Konsol Riset Menjadi Layanan Publik

Laporan sampai Bagian 11 berakhir pada satu temuan yang tidak bisa dijawab dengan penalaan: korpus smishing Bahasa Indonesia berlabel manusia belum ada yang publik (Bagian 8). Siskamling Digital adalah jawaban proyek ini atas temuan itu — bukan model baru, melainkan **layanan** yang membangun korpusnya: warga melapor, manusia memverifikasi, korpus terbangun dari laporan nyata.

Asal-usulnya persis dari riset. Tahap 2A dan 2D terpaksa mengandalkan keluarga templat karena tidak ada data Indonesia asli yang bisa dipakai; risiko artefak templat dicatat apa adanya di Bagian 10. Satu-satunya jalan keluar yang jujur adalah mengumpulkan pesan smishing sungguhan dari warga, membersihkannya dari data pribadi, dan melabelinya oleh manusia. Itulah misi layanannya: *ronda warga digital untuk pesan penipuan* — warga memeriksa dan melaporkan pesan mencurigakan, dan laporan terverifikasi menjadi data yang membuat model Indonesia bisa dipakai.

Nama & rumah layanan. Nama **"Siskamling Digital"** lolos cek bentrok nama di DJKI. Layanannya hidup di aplikasi Streamlit yang **sama** dengan konsol Fraud Triage — satu app, dua wajah: konsol analis dan layanan warga. Demo live: https://fraud-triage-demo.streamlit.app/

Fase 0 — Fondasi data, sebelum satu laporan pun diterima

Fase 0 adalah gerbangnya: skema, persetujuan (consent), dan pembersih data pribadi harus beres sebelum publik diundang melapor. Basis datanya **Turso** (SQLite edge, Tokyo) bernama **siskamling-digital** — terpisah dari basis data proyek lain.

Komponen	Isi & aturan mainnya
reports	Satu baris per laporan: teks hasil scrub, kanal, kategori modus, skor & band model, sinyal aturan, persetujuan data, status verifikasi, label manusia
consent_log	Jejak persetujuan per laporan: versi teks consent yang disetujui + hash teksnya, agar versi yang berlaku untuk tiap laporan dapat dibuktikan
corpus_export (view)	**Satu-satunya pintu keluar data latih.** Hanya baris berstatus terverifikasi + consent penggunaan data = 1 + berlabel yang bisa diekspor menjadi korpus

Identitas & privasi setiap laporan

- **Nomor laporan unik.** Setiap laporan menerima id unik, ditampilkan sebagai **"Nomor laporan #…"** — bukti penerimaan pelapor.
- **Nomor pengirim tidak pernah disimpan mentah** — hanya **sender_hash**: SHA-256 satu arah dari nomor ternormalisasi + garam produksi; mengenali pengirim berulang, tidak bisa dibalik ke nomor asli.
- **created_at = waktu submit.** Tanggal tercatat adalah tanggal laporan dikirim warga, bukan tanggal verifikasi.
- **Teks yang disimpan hanya hasil scrub** — versi yang sudah dibersihkan otomatis dari data pribadi (Fase 1); teks mentah tidak pernah masuk basis data.

BAGIAN 12 — LANJUTAN

Lapor & Cek, Verifikasi Manusia, Analitik

Fase 1 — v5.5.0 · commit 83e738d

Dua tab warga pertama dibuka di app yang sama:

- **Tab Lapor & Cek** — warga menempel pesan mencurigakan, menerima hasil cek awal dari model Fraud Triage yang sama dengan konsol (ensemble CHOSEN + lapisan aturan), dan dapat mengirimkannya sebagai laporan tercatat bernomor unik.
- **Galeri Modus** — modus-modus yang sudah terverifikasi tampil tanpa nama dan tanpa data pribadi, agar warga lain mengenali polanya sebelum menjadi korban.
- **Scrubber otomatis** — sebelum teks disimpan, pola data pribadi dibuang otomatis (nomor telepon, tautan pribadi, email, nomor rekening/kartu, NIK; domain tautan dipertahankan sebagai sinyal modus). Pola **OTP sengaja dipertahankan**: kode OTP di dalam pesan adalah sinyal isi penipuan, bukan identitas pelapor.

Fase 2 — v5.6.0 · commit 3d505c3

Tab Verifikasi untuk admin, bergerbang kata sandi. Di dalamnya: antrean laporan berstatus *pending* yang terurut skor risiko — tertinggi di atas, mengikuti pola antrean triase analis di Bagian 11 — lengkap dengan saran mesin per laporan.

> **Doktrin verifikasi: label akhir selalu diputuskan manusia.**
>
> Saran mesin ditampilkan untuk mempercepat peninjauan, tetapi tidak pernah menjadi label. Model yang melabeli data latihnya sendiri itu **sirkular** dan meracuni korpus — korpus Siskamling hanya berisi label manusia, sesuai desain Fase 0. Hanya laporan terverifikasi + consent yang tampil di galeri dan masuk *corpus_export*.

Panel Analitik — v5.7.0 · commit 14fdd5e

Di dalam tab Verifikasi, panel Analitik membaca denyut layanan dari basis data yang sama: total laporan; laporan 7 hari terakhir; pengirim unik & pengirim berulang (dihitung dari sender_hash); tingkat consent; rata-rata waktu verifikasi; corong status (pending → terverifikasi / ditolak); progres korpus per label menuju target sekitar 1.000; grafik harian 14 hari; serta modus, kanal, dan kategori terbanyak.

Sengaja tidak dihitung: jumlah kunjungan halaman **tidak** dihitung di dalam app. Itu ranah dashboard Streamlit Cloud; penghitung sesi buatan sendiri akan menyesatkan karena satu warga bisa membuka banyak sesi. Analitik layanan ini hanya menghitung hal yang benar-benar tercatat di basis data.

BAGIAN 12 — LANJUTAN

Hardening & Wajah Warga

Fase 2.5 Hardening — v5.8.0 · commit 464a71b

Formulir publik adalah permukaan serangan. Sebelum promosi, intake laporan dikeraskan berlapis:

Pertahanan	Aturan
Batas laju per pengirim	Maksimum **10 laporan / pengirim / hari** (dikenali via sender_hash)
Batas laju global	Maksimum **300 laporan / hari** untuk seluruh layanan
Pemutus antrean	Intake berhenti bila antrean *pending* mencapai **500**
Jeda sesi	**20 detik** antar pengiriman dalam satu sesi
Deteksi duplikat	*text_hash* atas teks ternormalisasi — pesan yang sama berulang dikenali sebagai duplikat
Kill switch intake	Flag *app_config*, dibalik dari tab Verifikasi — tutup/buka intake tanpa deploy ulang
Monitor lonjakan	Berkala: **≥ 20 laporan/jam** → peringatan; **≥ 100/jam** → intake ditutup **otomatis** + kabar
Cadangan basis data	Ekspor cadangan **mingguan otomatis**, bergulir 8 minggu

UI/UX Warga — v5.9.1 · commit 0d670fe

Urutan tab dibalik menjadi **warga-dulu**: tab **Lapor & Cek menjadi tab pendaratan**, mendahului tab-tab konsol analis. Di atas formulir, hero layanan berbunyi: **“Cek dulu, sebelum klik.”** Hasil cek tidak lagi berbicara dalam band teknis kepada warga:

Vonis bahasa warga	Makna operasionalnya
● **Hampir pasti penipuan**	Band ESKALASI — jangan klik, jangan balas, laporkan
● **Mencurigakan, hati-hati**	Band REVIEW — verifikasi lewat kanal resmi di luar pesan
● **Kemungkinan aman**	Band AUTO-CLOSE — tetap waspada; hasil cek adalah triase awal, bukan jaminan

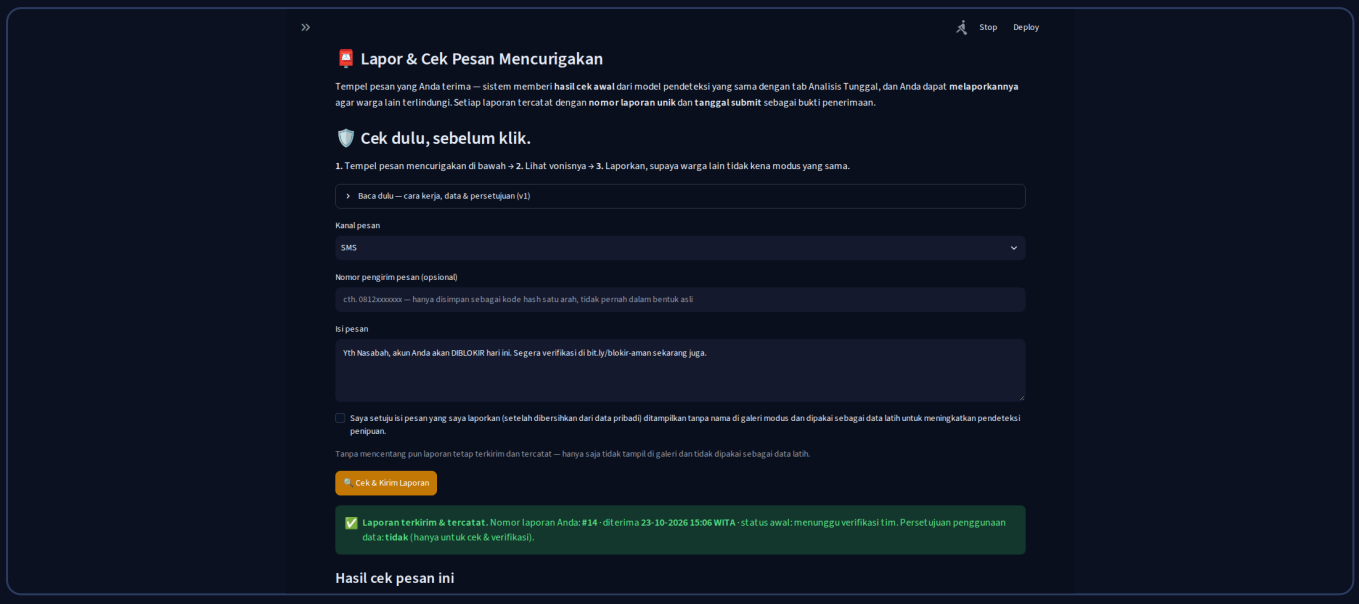
Setiap vonis ditemani **langkah tindakan** konkret dan **tanda bahaya bahasa awam**. Kartu teknis tidak hilang — dilipat ke expander **“Detail teknis”**. Galeri Modus mendapat **filter kategori berbahasa awam**.

Cloudflare Turnstile: terpasang, dorman.

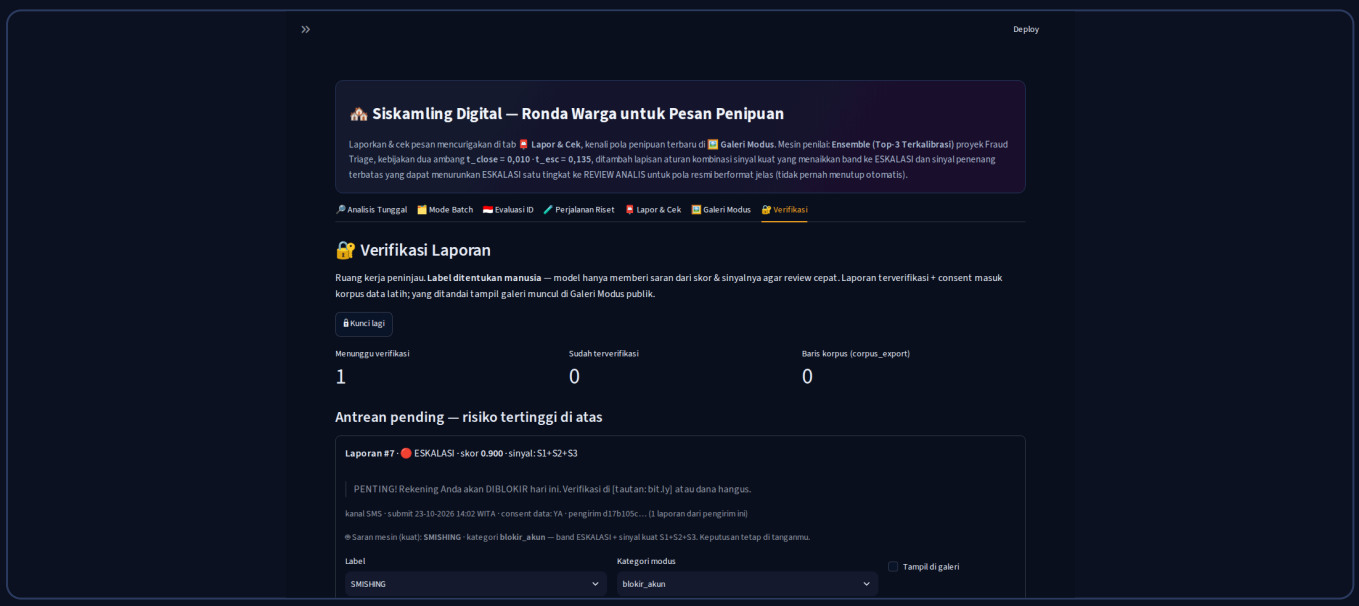
Kedua kunci terpasang, tetapi flag *app_config* **turnstile_on = 0**. Catatan jujur: jabat tangan widget **belum terbukti** di lingkungan uji sandbox penulis (komponen kanonis pun gagal di sana — batasan lingkungan, bukan bukti widget rusak); verifikasi widget dilakukan **terkendali di app live**. Kebijakan aktivasi: serangan terbukti / sebelum promosi ke audiens dingin / pola bot pada data.

BAGIAN 12 — GALERI LAYANAN

Siskamling Digital dalam Gambar



Tab Lapor & Cek (v5.9): hero “Cek dulu, sebelum klik.”, formulir kanal + nomor pengirim opsional (keterangan tegas: hanya disimpan sebagai kode hash satu arah), teks persetujuan v1, dan bukti penerimaan hijau berisi **Nomor laporan #14** + tanggal submit — persis identitas laporan yang dirancang di Fase 0.



Tab Verifikasi: penghitung menunggu / terverifikasi / baris korpus, lalu antrean pending terurut risiko tertinggi di atas. Laporan #7 tampil dengan skor, sinyal S1+S2+S3, teks yang sudah terscrub (tautan ditopeng menjadi penanda domain), dan **saran mesin** — sementara pilihan Label dan Kategori modus tetap berada di tangan peninjau manusia.

BAGIAN 12 — PENUTUP BAGIAN

Versi, Status Jujur, Langkah Berikutnya

Tabel versi layanan

Versi	Commit	Isi rilis
v5.5.0	83e738d	Fase 1 — tab Lapor & Cek + Galeri Modus; scrubber otomatis
v5.6.0	3d505c3	Fase 2 — tab Verifikasi admin bergerbang kata sandi; label hanya oleh manusia
v5.7.0	14fdd5e	Panel Analitik layanan di tab Verifikasi
v5.8.0	464a71b	Fase 2.5 Hardening — batas laju, duplikat, kill switch, monitor lonjakan, backup mingguan
v5.9.1	0d670fe	UI/UX warga (tab pendaratan, hero, vonis bahasa warga) + Turnstile dorman

Status jujur saat edisi ini terbit: basis data korpus masih 0 laporan.

Seluruh mesin layanannya sudah terverifikasi bekerja — laporan uji tercatat persis di basis data lalu dihapus, sehingga basis data kembali bersih. Pengumpulan korpus yang sesungguhnya **dimulai saat peluncuran publik**. Angka nol ini ditampilkan apa adanya, dengan semangat yang sama seperti vonis 2/4 gerbang di sampul laporan ini.

Langkah berikutnya

- **Fase 3 — Distribusi & pengumpulan korpus.** Menyebarluaskan layanan agar laporan warga nyata mengalir masuk, diverifikasi manusia, dan korpus tumbuh menuju target sekitar **1.000 label**.
- **Fase 4 — Retrain yang disiplin.** Pelatihan ulang hanya dilakukan dengan **set hakim BARU** dan **gerbang yang dikunci di muka** — doktrin anti-overfitting proyek ini (Bagian 7) tidak berubah hanya karena datanya kini data asli.

Catatan kepenulisan

Proyek ini dibangun dengan bantuan AI sebagai *pair engineer*; arsitektur, gerbang evaluasi, dan setiap keputusan akhir dipegang dan diverifikasi sendiri oleh **Septian Panjaya**.

Dengan Bagian 12 ini, busur proyeknya utuh: konsol riset membuktikan datanya belum ada — layanan publiknya kini mengumpulkan data itu, satu laporan warga terverifikasi pada satu waktu.

PENUTUP

Tautan & Cara Menjelajahi Proyek Ini

Artefak	Tautan
Demo live (Streamlit Cloud, app v5.4.0)	https://fraud-triage-demo.streamlit.app/
Kode sumber (GitHub: app, rules, journey, results)	https://github.com/rwnliwan/fraud-triage
Model (Hugging Face: bobot DistilBERT + artefak ensemble)	https://huggingface.co/rwnliwan/fraud-triage-smishing
Notebook riset (arsip lengkap Tahap 0–2D)	*fraud-triage-laya-vs-ml-dl.ipynb* — tersimpan di folder proyek & Google Drive “Fraud Triage Laya”

Satu kalimat penutup

Proyek ini tidak menghasilkan model yang lolos klaimnya — proyek ini menghasilkan **bukti yang bisa diperiksa** tentang sejauh mana model itu sampai, di mana persisnya ia gagal, dan kenapa kegagalan itu berakar pada data yang memang belum ada. Untuk pekerjaan risk analytics, bukti seperti itu lebih berharga daripada skor yang dibulatkan naik.

Catatan kejujuran visual: screenshot aplikasi di laporan ini ditangkap dari instance lokal yang menjalankan kode & model yang identik dengan versi live v5.4.0. Seluruh angka berasal dari berkas evaluasi terverifikasi proyek; angka benchmark arena dari kartu benchmark aplikasi (hasil arena test notebook).

Fraud Triage adalah proyek pembelajaran terpimpin (guided project) di bidang fraud/AML risk analytics. Model di dalamnya adalah artefak pembelajaran — bukan sistem produksi perbankan, dan tidak untuk dipakai memvonis pesan pengguna nyata tanpa korpus Indonesia segar, kalibrasi ulang, dan pengawasan manusia.