

Fraud Triage

SMS penipuan menyedot rekening — sementara analis kebanjiran pesan yang harus diperiksa satu per satu.

92,7% pesan sah akhirnya dikenali benar. Perjalanan mencapainya tidak mulus — dan kegagalannya justru temuan terpentingnya.

Model Inggris yang hebat di kertas, runtuh di pesan Indonesia

16%

Hanya segitu pesan **SAH** Indonesia yang dikenali benar di Tahap 0 — dinilai pada set hakim 300 pesan yang tidak pernah dipakai melatih model.

84 dari 100 pesan resmi ikut dieskalasi. Pesan yang terdengar resmi justru terbaca mencurigakan — register Indonesia tidak pernah ada di data latih Inggris ±2011.

Tiga lapis: skor, ambang, aturan

1 **Ensemble Top-3 terkalibrasi**

DistilBERT multilingual + dua model TF-IDF / Logistic Regression. Skornya adalah peringkat triase — bukan vonis.

▼

2 **Dua ambang keputusan**

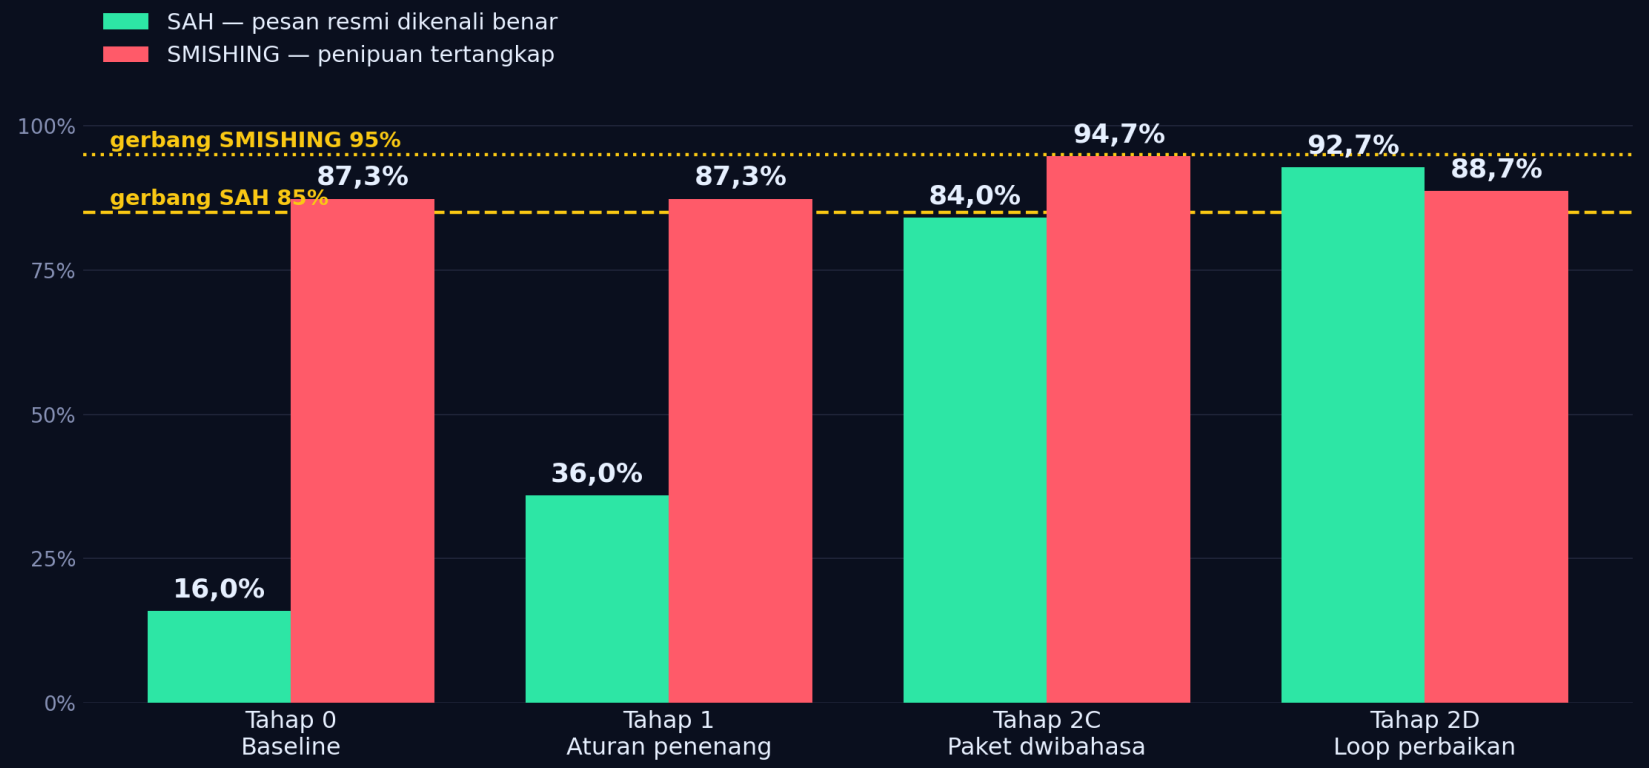
t_close 0,010 — di bawahnya kasus ditutup otomatis. t_esc 0,135 — di atasnya langsung eskalasi. Di antaranya: manusia yang memeriksa.

▼

3 **Lapisan aturan S1–S3 + sinyal penenang**

Sinyal keras hanya menaikkan band. Sinyal penenang resmi boleh menurunkannya tepat satu tingkat — dan gugur bila ada sinyal kuat.

SAH naik 16% → 92,7% — SMISHING justru mundur di langkah terakhir



Setiap tahap dinilai full-stack pada set hakim yang sama. Garis kuning = gerbang klaim yang dikunci sebelum eksperimen dimulai.

Klaim 9/10: gagal 2 dari 4 gerbang

92,7%

SAH ✅

Gerbang ≥ 85% — pesan resmi dikenali benar

88,7%

SMISHING ❌

Gerbang ≥ 95% — kurang 9 pesan dari target

2

Smishing AUTO-CLOSE ❌

Gerbang = 0 — penipuan yang tertutup otomatis tanpa dilihat manusia

0,9882

PR-AUC Inggris ✅

Gerbang ≥ 0,98 — kemampuan pada data Inggris tidak rusak

Model di aplikasi tidak ditukar. Kegagalannya didokumentasikan apa adanya — bukan digeser ambangnya sampai terlihat lolos.

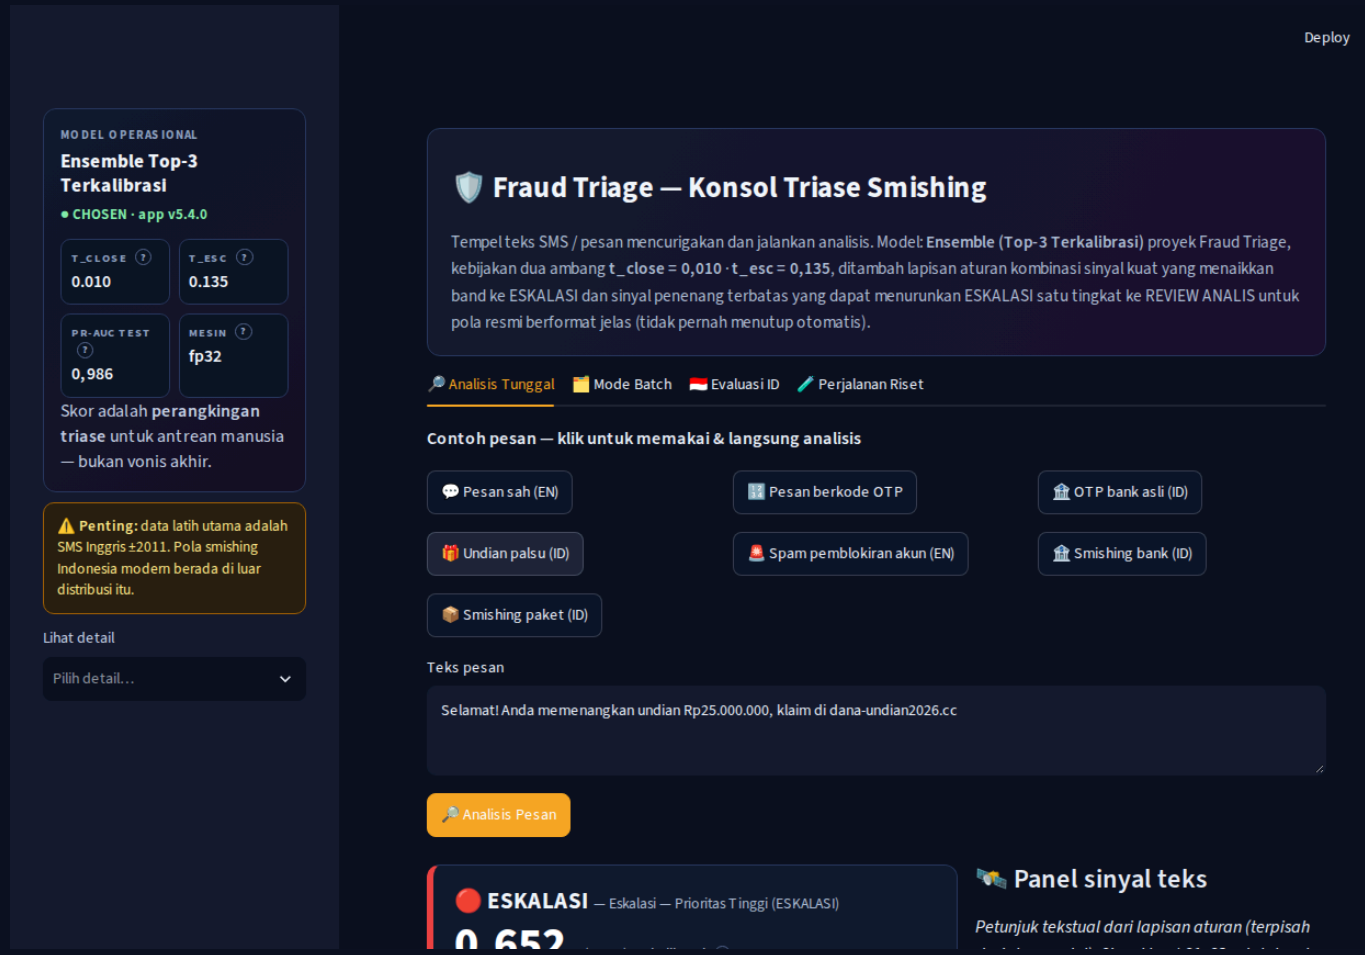
Gagalnya struktural: datanya memang tidak ada

0

Dataset **smishing Indonesia** yang publik dan bisa dipakai: nol.

Yang tersisa hanya korpus SMS 3-kelas berisi 1.143 baris dari era 2013–2015. Data regulator dan operator ada — tetapi tertutup.

Sebagian besar korpus latih proyek ini akhirnya harus dibangun sendiri: 2.512 baris, lolos gerbang anti-bocor terhadap set hakim.



Satu pesan masuk, vonisnya transparan

Kartu ESKALASI — band keputusan tampil di muka, bukan disembunyikan.

Panel sinyal — alasan skornya bisa dibaca analis, sinyal demi sinyal.

Skor terkalibrasi — angka yang sama dipakai untuk mengurutkan antrean.

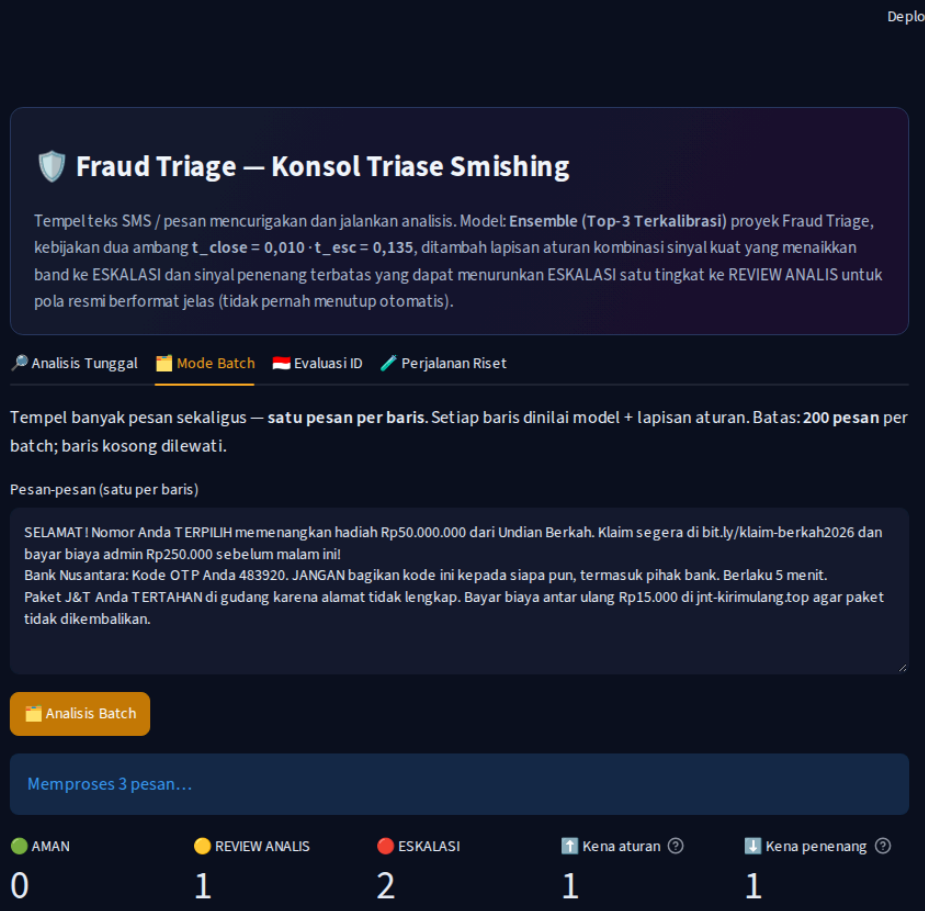
Mesin mengurutkan, manusia memutuskan

Antrean prioritas — ratusan pesan terurut dari yang paling berisiko.

Detail per kasus — analis membuka, memeriksa, lalu memutuskan.

Laporan kasus .md — hasil triase bisa diunduh per kasus.





Polanya bisa dipakai di mana pun analis kebanjiran laporan



Antrean triase bank & fintech

Laporan pesan mencurigakan terurut prioritas sebelum menyentuh analis.



Operasi CS e-wallet & telco

Volume laporan harian disaring: yang mendesak naik duluan.



Pusat pengaduan

Filter awal pengaduan penipuan digital dengan jejak alasan yang jelas.



Artefak pembelajaran

Contoh utuh: kalibrasi sebelum kebijakan, gerbang klaim dikunci di muka.

Jujur saja: **bobot modelnya belum siap produksi** — yang bisa dipakai ulang hari ini adalah pola & pipeline-nya.

Tiga batasan yang tidak disembunyikan

1

Data latih Inggris ±2011

Fondasi modelnya tua dan berbahasa lain. Korpus Indonesia dibangun sendiri — dan tetap kecil.

2

Set hakim sudah terbakar

300 pesan penilai yang sama dipakai berulang — untuk iterasi berikutnya, ia tidak lagi netral. Set hakim baru wajib dibuat.

3

Antrean manusia tetap pengikat

Di Tahap 2D, pesan SAH yang berhenti di REVIEW naik 23 → 47. Di volume besar, kapasitas analis — bukan model — yang menentukan.

Dari riset ke layanan: korpus yang tidak ada, dibangun dari warga

→

Temuan proyek

Korpus smishing Bahasa Indonesia berlabel manusia belum ada yang publik. Itulah akar gagalnya model — dan celah yang bisa ditutup warga sendiri.

→

Misinya berubah

Layanan publik untuk cek & lapor pesan mencurigakan — yang sekalian membangun korpus itu, laporan demi laporan, dengan izin pelapornya.

🏘

Siskamling Digital — sudah live

Nama lolos cek bentrok nama DJKI. Ronda kampung, versi digital: warga saling menjaga dari penipuan pesan. fraud-triage-demo.streamlit.app

Untuk warga: cek dulu, sebelum klik

🔍

Cek — vonis dalam bahasa awam

Tempel pesan, dapat vonis: 🔴 Hampir pasti penipuan · 🟡 Mencurigakan · 🟢 Kemungkinan aman — lengkap dengan langkah tindakan yang harus diambil.

📮

Lapor — pribadi dibersihkan otomatis

Teks laporan dibersihkan dari data pribadi sebelum disimpan. Pengirim tidak disimpan apa adanya — hanya sebagai hash satu arah.

🖼️

Galeri Modus — kenali polanya dulu

Modus terverifikasi yang bisa disaring per kategori, supaya warga mengenali pola penipuan sebelum menjadi korban.

Mesin menyaring, manusia memutuskan

1 **Scrub**
Data pribadi dibersihkan dari teks laporan sebelum apa pun disimpan.

▼

2 **Hash**
Pengirim disimpan hanya sebagai hash satu arah — tidak bisa dibalik menjadi nomor aslinya.

▼

3 **Saran mesin**
Model memberi saran label untuk mempercepat antrean verifikasi.

▼

4 **Label akhir: selalu manusia**
Lewat gerbang kata sandi admin. Model yang melabeli data latihnya sendiri itu sirkular — vonisnya tidak akan pernah netral.

Satu-satunya pintu masuk korpus: view **corpus_export** — hanya laporan terverifikasi + consent + berlabel manusia.

Dibangun untuk publik beneran, bukan demo sekali pakai

🚦

Batas laju & anti-duplikat

Maksimum 10 laporan per pengirim per hari dan 300 per hari secara keseluruhan. Laporan duplikat terdeteksi dan tidak menggandakan antrean.

🛑

Pemutus & kill switch

Antrean pending yang membengkak memutus intake. Kill switch intake bisa ditutup manual kapan saja dari tab Verifikasi.

📈

Monitor lonjakan & cadangan

Lonjakan ≥100 laporan per jam menutup intake otomatis dan memberi kabar. Cadangan korpus diekspor mingguan.

🧭

UI warga & Turnstile dorman

Tab Lapor mendarat pertama, hero “Cek dulu, sebelum klik.” Cloudflare Turnstile terpasang dorman — aktif saat dibutuhkan.

Hardening v5.8 · UI warga v5.9 — disiapkan sebelum ramai, bukan sesudah kejadian.

Status jujur: korpusnya mulai dari nol, hari ini

0

Label di korpus saat peluncuran. Pengumpulan dimulai sekarang — bukan angka yang diklaim sudah ada.

±1.000

Target label berlabel manusia. Setiap label lewat verifikasi admin, bukan label otomatis.

Fase 4

Retrain hanya dengan set hakim baru — dan gerbangnya dikunci di muka, sebelum hasil dilihat.

Tidak ada retrain diam-diam di tengah jalan: korpus tumbuh dulu, hakimnya baru, gerbangnya terkunci — urutannya tidak ditukar.

Coba layanannya. Baca kegagalannya. Pakai polanya.

🔗 **fraud-triage-demo.streamlit.app**

💻 **github.com/rwnliwan/fraud-triage**

🤗 **huggingface.co/rwnliwan/fraud-triage-smishing**

Laporan teknis lengkap — model, data, tahapan, perlakuan, evaluasi — tersedia sebagai dokumen terpisah.

Dibangun dengan bantuan AI sebagai pair engineer; arsitektur, gerbang evaluasi, dan setiap keputusan & verifikasi akhir oleh Septian.