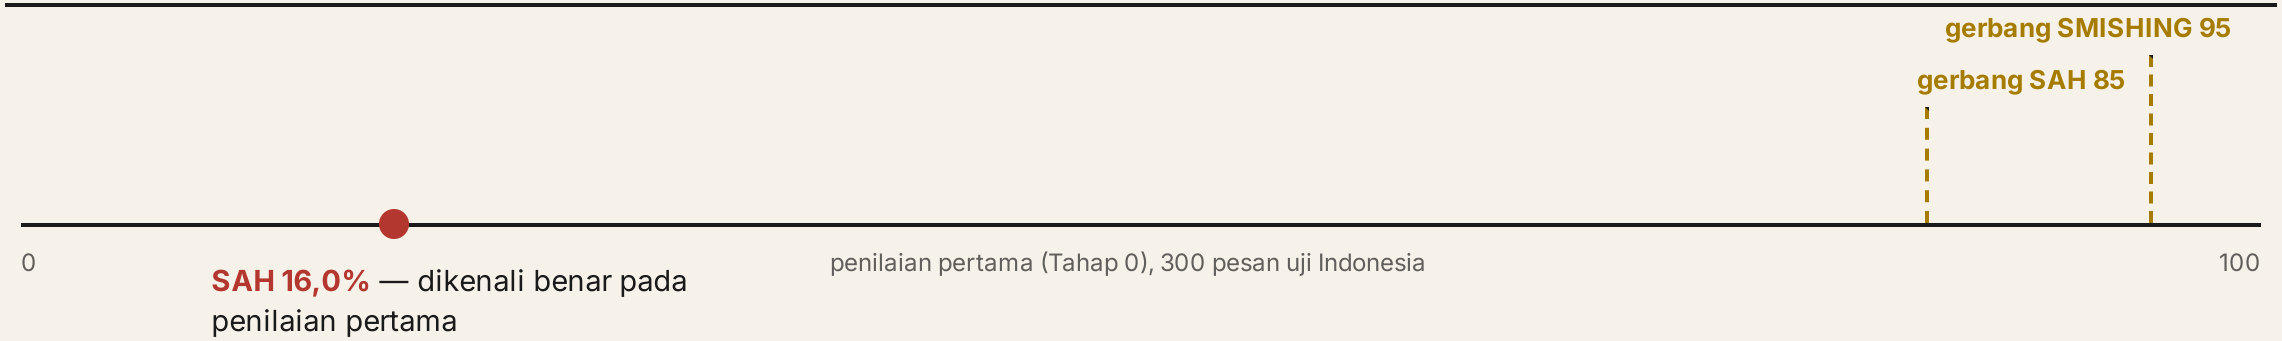
Fraud Triage — proyek penyaringan pesan penipuan (smishing)

## SMS ini dari bank beneran — atau penipu?

# AI saya salah menebak 84 dari 100 pesan resmi Indonesia.

Kegagalannya didokumentasikan apa adanya — lalu diubah jadi layanan. **Siskamling Digital**: warga cek & lapor pesan penipuan, dan setiap laporan yang diperiksa manusia membangun kumpulan contoh pesan penipuan (korpus). Kumpulan itu selama ini tidak ada.



01

bagian pertama

# Riset

Sebuah model dilatih di data Inggris, diuji pada pesan Indonesia, dan syarat lulusnya dikunci di muka — sebelum hasilnya dilihat.

---

**a** Masalah & latar belakang **b** Pendekatan, data & model **c** Perjalanan & vonis **d** Aplikasi & batasan

# Model Inggris yang hebat di kertas, runtuh di pesan Indonesia

**16%**

Hanya segitu pesan **SAH** Indonesia yang dikenali benar di Tahap 0 — dinilai pada 300 pesan uji (set hakim) yang tidak pernah dipakai melatih model.

84 dari 100 pesan resmi ikut diteruskan ke pemeriksaan manusia. Pesan yang terdengar resmi justru terbaca mencurigakan — gaya bahasa resmi Indonesia tidak pernah ada di data latih Inggris ±2011.

# Penipuan SMS itu masalah publik — bukan sekadar masalah model

## 1 Modusnya menyamar jadi institusi resmi

Pesan penipuan datang sebagai bank, kurir, telco, sampai instansi pemerintah. Korbannya lintas usia — dan kerugiannya bisa terjadi dalam satu klik.

## 2 Data pembandingnya tertutup

Data penipuan di regulator & industri tidak dibuka. Riset data proyek ini hanya menemukan kumpulan pesan 3-kelas 1.143 baris (±2012–2016) — terlalu tua & kecil; kumpulan pesan berlabel manusia yang publik = 0.

## 3 Lensa pencegahan: mencegah lebih murah

Dari latar kesehatan masyarakat: menangani korban selalu lebih mahal daripada mencegahnya. Layanan ini dibangun sebagai pencegahan, bukan pemadam kebakaran.

## 4 Siskamling: ronda warga, versi digital

Namanya dari ronda malam — warga jaga bersama, lapor bersama. Itulah asal nama Siskamling Digital: keamanan sebagai kerja bersama, bukan urusan korban sendirian.

**Maka** kekosongan itu diisi oleh warga sendiri — lewat laporan mereka.

# Tiga lapis: skor, ambang, aturan

## 1 Gabungan tiga model (ensemble)

Satu model bahasa (DistilBERT) + dua model statistik kata (TF-IDF / Logistic Regression). Skornya adalah peringkat penyaringan — bukan vonis.

## 2 Dua ambang keputusan

Ambang bawah 0,010 — di bawahnya kasus ditutup otomatis. Ambang atas 0,135 — di atasnya langsung diteruskan. Di antaranya: manusia yang memeriksa.

## 3 Lapisan aturan S1–S3 + sinyal penenang

Sinyal keras hanya menaikkan tingkat keputusan. Sinyal penenang resmi boleh menurunkannya tepat satu tingkat — dan gugur bila ada sinyal kuat.

# Model dilatih pada SMS Inggris ±2011 — dan dinilai pada 300 pesan Indonesia yang belum pernah dilihatnya

**1**

## Data latih babak seleksi

Kumpulan pesan spam/penipuan Bahasa Inggris publik (era ±2011).

**2**

## Pesan uji (set hakim) Indonesia

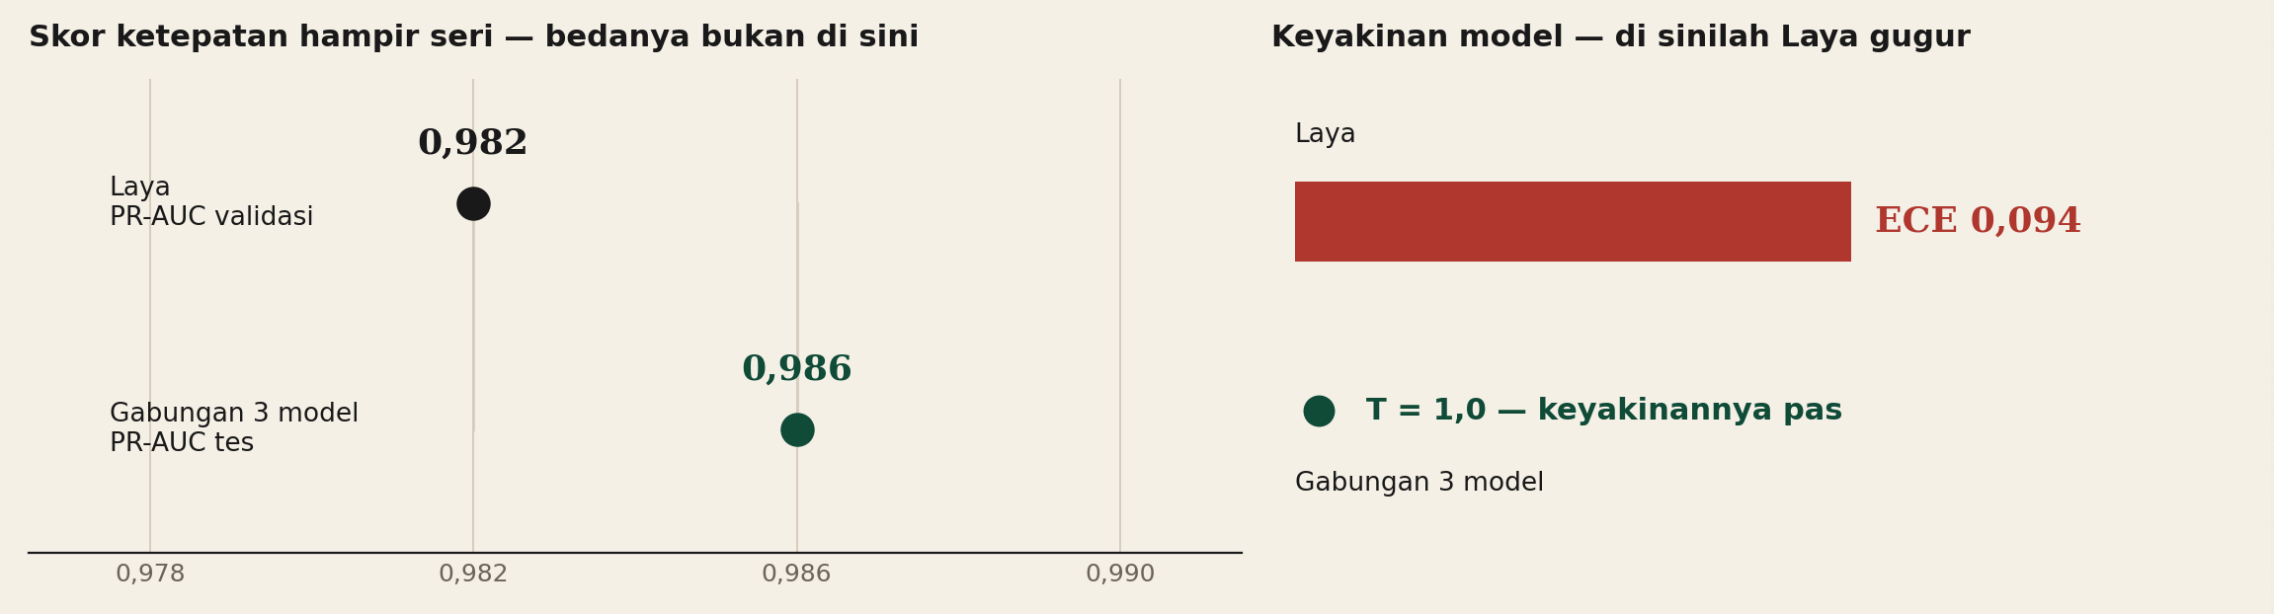
300 pesan, TIDAK pernah jadi data latih — khusus menguji klaim.

**3**

## Hasil riset data Indonesia

Kumpulan pesan 3-kelas 1.143 baris (±2012–2016, terlalu tua/kecil), data regulator tertutup → kesimpulan: kumpulan pesan penipuan Indonesia berlabel manusia yang publik = 0.

# Dua kandidat akhir, skornya seri — angka keyakinannya yang membedakan




**Gambar 1 —** Dua kandidat akhir: skor ketepatannya (PR-AUC) hampir seri — yang membedakan, seberapa bisa dipercaya angka keyakinannya.

**Laya — model bahasa (BERT) yang dilatih ulang.** Angka keyakinannya meleset jauh (ECE 0,094) dan lambat (2,81 detik/pesan). ● **GUGUR**

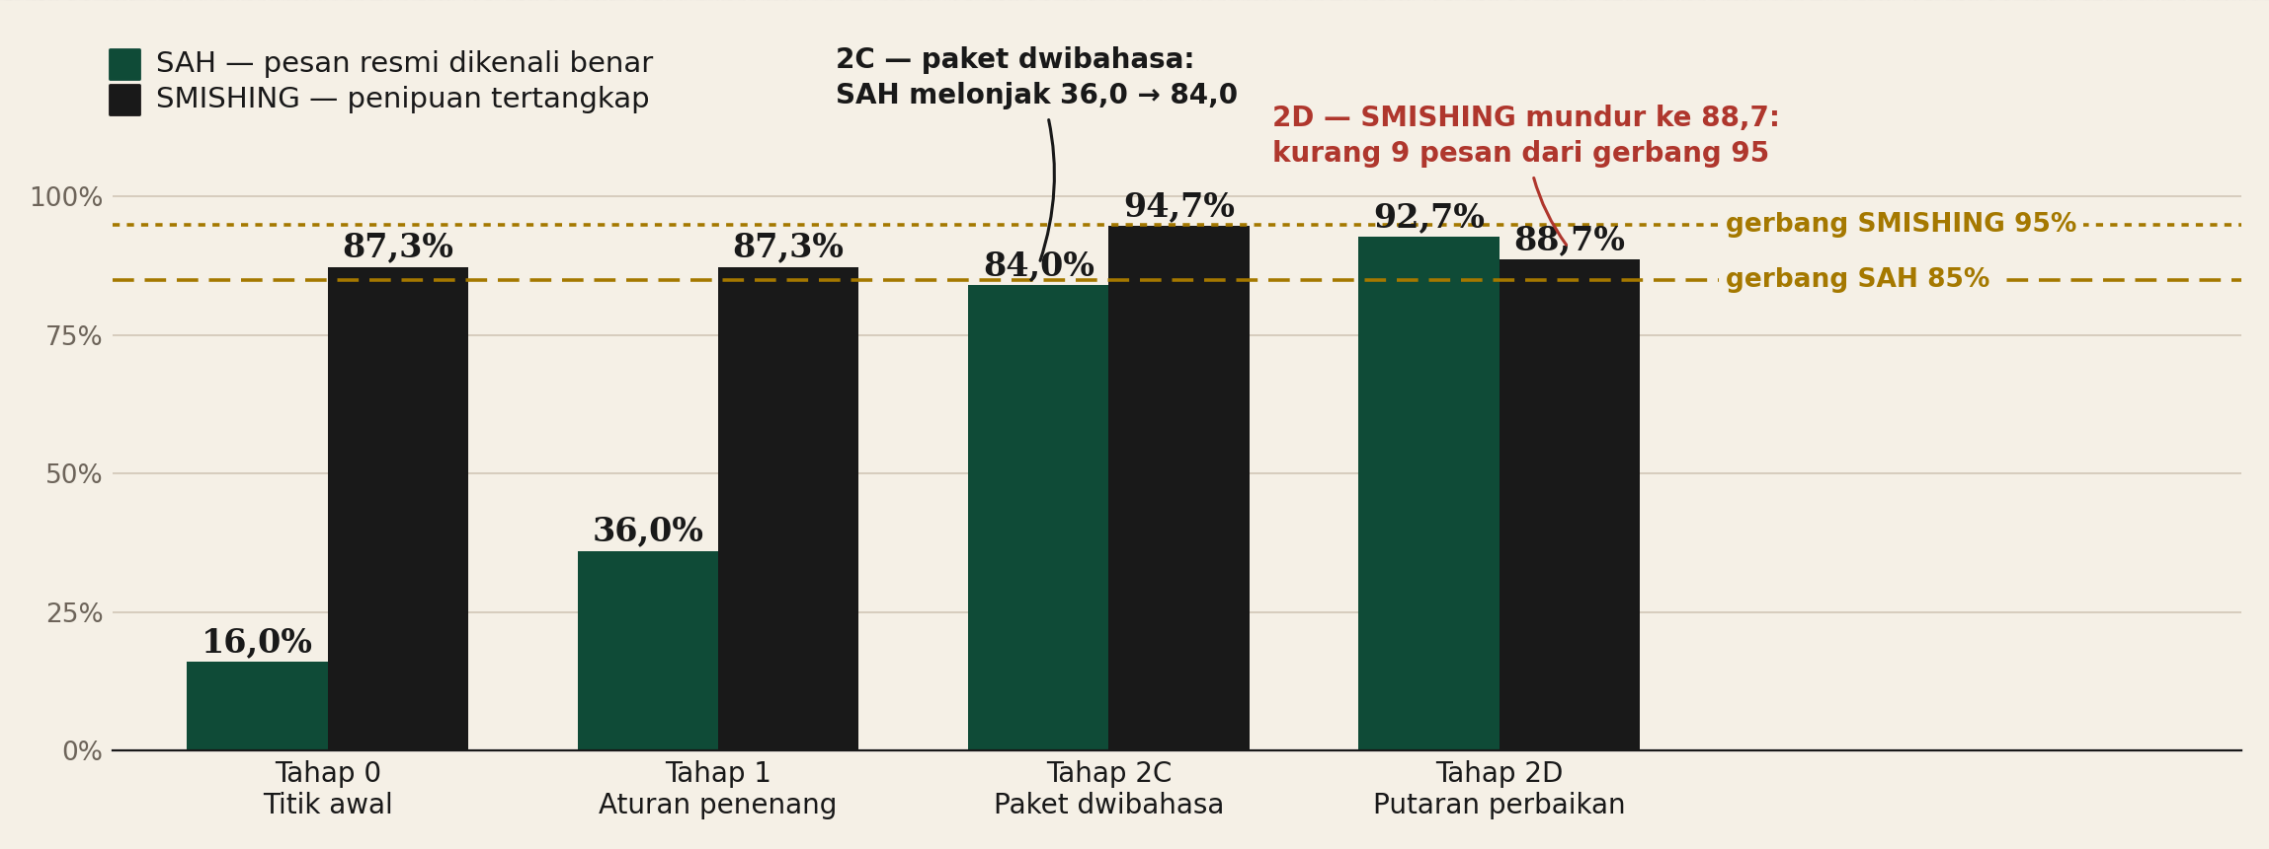
**Gabungan tiga model.** Keyakinannya terpercaya (T = 1,0), cepat — tetap model aplikasi sampai hari ini. ● **TERPILIH (CHOSEN)**

**babak seleksi**
6 kandidat model diuji pada kumpulan pesan Inggris yang sama.

**finalis**
Laya vs gabungan tiga model — dua yang tersisa di ujung seleksi.

**penentu**
Bukan skor tertinggi di satu ukuran — yang keyakinannya bisa dipercaya & layak operasi.

# SAH naik 16% → 92,7% — SMISHING justru mundur di langkah terakhir




**Gambar 2 —** Setiap tahap dinilai sebagai satu paket utuh pada pesan uji yang sama. Garis kuning = syarat lulus (gerbang) yang dikunci sebelum percobaan dimulai.

# Klaim 9/10: gagal 2 dari 4 gerbang

## 92,7%

**SAH**

Gerbang ≥ 85% — pesan resmi dikenali benar

## 88,7%

**SMISHING**

Gerbang ≥ 95% — kurang 9 pesan dari target

## 2

**Smishing tertutup otomatis (AUTO-CLOSE)**

Gerbang = 0 — penipuan yang tertutup otomatis tanpa dilihat manusia

## 0,9882

**Skor ketepatan (PR-AUC) pada data Inggris**

Gerbang ≥ 0,98 — kemampuan pada data Inggris tidak rusak

Total akhir Tahap 2D: **90,7%** · panel uji **16/16** — dan klaimnya tetap gagal 2 dari 4 gerbang.

Model di aplikasi tidak ditukar. Kegagalannya didokumentasikan apa adanya — bukan digeser ambangnya sampai terlihat lolos.

# Gagalnya mendasar: datanya memang tidak ada

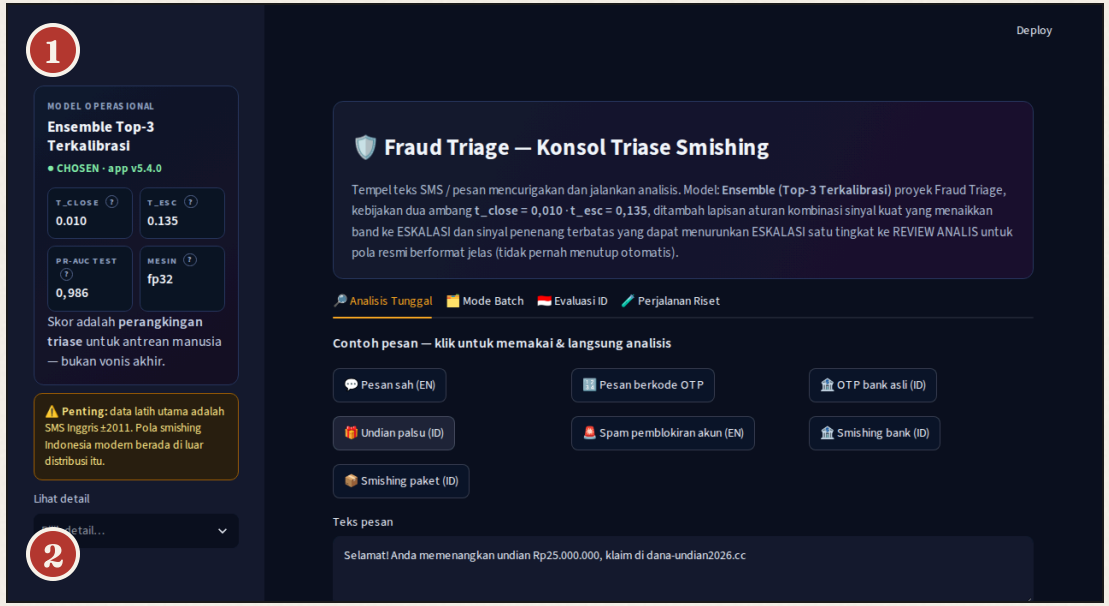
**0**

**Kumpulan pesan penipuan** (smishing) Indonesia yang publik dan bisa dipakai: nol.

Yang tersisa hanya kumpulan pesan SMS 3-kelas berisi 1.143 baris dari era ±2012–2016. Data regulator dan operator ada — tetapi tertutup.

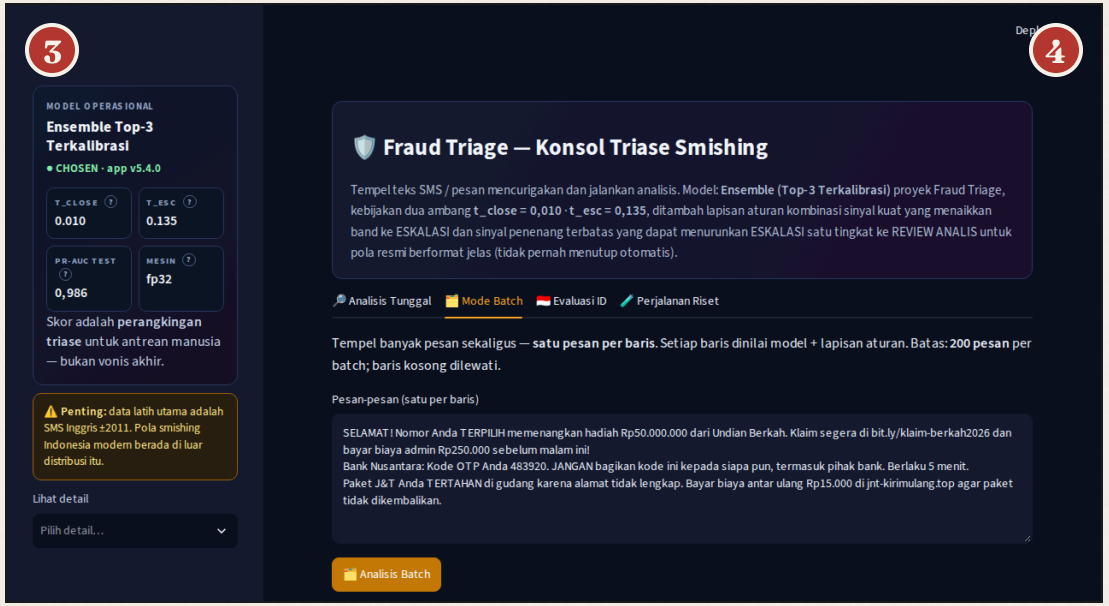
Sebagian besar kumpulan pesan latih proyek ini akhirnya harus dibangun sendiri: 2.512 baris, sudah diperiksa agar tidak bocor ke pesan uji.

# Dua mode, satu prinsip: transparan di muka, manusia yang memutuskan




**Gambar 3a — Analisis Tunggal.** 1 kartu tingkat keputusan tampil di muka · 2 daftar sinyal: alasan skor terbaca satu per satu.

**Skor yang bisa dipercaya** — angka yang sama dipakai untuk mengurutkan antrean.




**Gambar 3b — Mode Batch.** 3 antrean ratusan pesan terurut prioritas risiko · 4 detail per kasus dibuka analis sebelum memutuskan.

**Laporan kasus** — hasil penyaringan bisa diunduh per kasus.

# Dipakai warga, dibangun warga, melindungi warga

## 1 Warga

Cek pesan sebelum klik — vonis dalam bahasa awam plus langkah tindakannya. Yang mencurigakan, laporkan sekalian: satu laporan bisa melindungi warga berikutnya.

## 2 Komunitas

Galeri Modus: modus-modus dari laporan nyata warga, terkelompok per kategori — edukasi yang hidup dari kejadian sebenarnya.

## 3 Kumpulan pesan

Setiap laporan yang diperiksa & dilabeli manusia masuk kumpulan pesan publik yang selama ini tidak ada — bahan latih model Indonesia berikutnya.

## 4 Analis

Konsol pemilahan memilah pola laporan yang masuk: mesin menyaring & memberi saran, label akhir selalu manusia.

**Lapor → Diperiksa manusia → Kumpulan pesan tumbuh → Model membaik → Warga lebih terlindungi**

**Bukan sekadar alat cek — kumpulan pesan penipuan Indonesia dari laporan warga, diperiksa & dilabeli manusia.**

# Tiga batasan yang tidak disembunyikan

## 1 Data latih Inggris ±2011

Fondasi modelnya tua dan berbahasa lain. Kumpulan pesan Indonesia dibangun sendiri — dan tetap kecil.

## 2 Pesan uji (set hakim) sudah terbakar

300 pesan penilai yang sama dipakai berulang — untuk iterasi berikutnya, ia tidak lagi netral. Set hakim baru wajib dibuat.

## 3 Antrean manusia tetap pengikat

Di Tahap 2D, pesan SAH yang berhenti di tahap periksa (REVIEW) naik 23 → 47. Di volume besar, kapasitas analis — bukan model — yang menentukan.

02

bagian kedua

# Layanan

Temuan risetnya berubah menjadi Siskamling Digital — layanan publik cek & lapor yang membangun kumpulan pesan yang tidak ada itu, laporan demi laporan dari warga.

---

**a** Misi & warga **b** Mesin menyaring, manusia memutuskan **c** Pengamanan & linimasa versi **d** Status jujur & pembeda

# Dari riset ke layanan: kumpulan pesan yang tidak ada, dibangun dari warga

→

## Temuan proyek

Kumpulan pesan penipuan (smishing) Bahasa Indonesia berlabel manusia belum ada yang publik. Itulah akar gagalnya model — dan celah yang bisa ditutup warga sendiri.

→

## Misinya berubah

Layanan publik untuk cek & lapor pesan mencurigakan — yang sekalian membangun kumpulan pesan itu, laporan demi laporan, dengan izin pelapornya.

→

## Siskamling Digital — sudah tayang

Nama lolos cek bentrok merek (DJKI). Ronda kampung, versi digital: warga saling menjaga dari penipuan pesan. fraud-triage-demo.streamlit.app

# Untuk warga: cek dulu, sebelum klik

## 1 Cek — vonis dalam bahasa awam

Tempel pesan, dapat vonis: 🔴 Polanya sangat mirip penipuan · 🟡 Mencurigakan · 🟢 Kemungkinan aman — lengkap dengan kartu langkah darurat sesuai keadaan, termasuk tautan resmi IASC OJK, cekrekening.id, dan aduannomor.id.

## 2 Lapor — pribadi dibersihkan otomatis

Laporan bisa ditempel sebagai teks, atau teksnya dibaca otomatis dari tangkapan layar. Isinya dibersihkan dari data pribadi sebelum disimpan; pengirim hanya disimpan sebagai kode samaran satu arah. Setiap laporan menerima nomor lacak untuk mengecek status pemeriksaannya.

## 3 Galeri Modus — kenali polanya dulu

Modus yang sudah diperiksa, bisa disaring per kategori, supaya warga mengenali pola penipuan sebelum menjadi korban.

# Mesin menyaring, manusia memutuskan.

## 1 Bersihkan data pribadi

Data pribadi dibersihkan dari teks laporan sebelum apa pun disimpan.

## 2 Samarkan pengirim

Pengirim disimpan hanya sebagai kode samaran satu arah — tidak bisa dikembalikan menjadi nomor aslinya.

## 3 Saran mesin

Model memberi saran label untuk mempercepat antrean pemeriksaan.

## 4 Label akhir: selalu manusia

Lewat gerbang kata sandi admin. Model yang melabeli data latihnya sendiri itu berputar-putar — hasilnya tidak akan pernah netral.

Satu-satunya pintu masuk kumpulan pesan: hanya laporan yang sudah diperiksa, disetujui pelapornya, dan dilabeli manusia.

# Dibangun untuk publik beneran, bukan demo sekali pakai

## 1 Batas jumlah & anti-duplikat

Maksimum 10 laporan per pengirim per hari dan 300 per hari secara keseluruhan. Laporan duplikat terdeteksi dan tidak menggandakan antrean.

## 2 Pemutus & tombol darurat

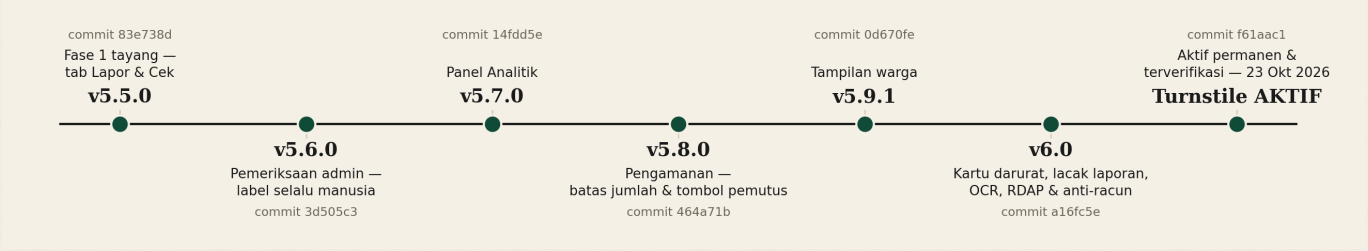
Antrean menunggu yang membengkak memutus penerimaan laporan. Penerimaan bisa ditutup manual kapan saja dari tab Verifikasi.

## 3 Monitor lonjakan & cadangan

Lonjakan ≥100 laporan per jam menutup penerimaan laporan otomatis dan memberi kabar. Cadangan kumpulan pesannya disimpan tiap minggu.

## 4 Tampilan warga & pemeriksa bot

Tab Lapor tampil pertama, dengan ajakan “Cek dulu, sebelum klik.” Pemeriksa bot Cloudflare (Turnstile) aktif permanen sejak 23 Oktober 2026, terverifikasi di perangkat asli.




**Gambar 4 —** Linimasa versi layanan: dari Fase 1 (v5.5.0) sampai v6.0 & Turnstile aktif, lengkap dengan kode versinya (commit) — ditutup 23 Oktober 2026 dengan Turnstile aktif permanen, terverifikasi di perangkat asli.

# Status jujur: kumpulan pesannya mulai dari nol, hari ini

**0**

**Label di kumpulan pesan** saat peluncuran. Pengumpulan dimulai sekarang — bukan angka yang diklaim sudah ada.

**±1.000**

**Target label** berlabel manusia. Setiap label lewat pemeriksaan admin, bukan label otomatis.

**Fase 4**

**Latih ulang** hanya dengan pesan uji baru — dan syarat lulusnya dikunci di muka, sebelum hasil dilihat.

Tidak ada latih ulang diam-diam di tengah jalan: kumpulan pesan tumbuh dulu, pesan ujinya baru, syarat lulusnya terkunci — urutannya tidak ditukar.

**Satu opsi terbuka di Tahap 3:** model khusus Indonesia — termasuk rilis terbaru saat itu — diuji ulang secara setara di arena yang sama. Yang dipertahankan bukan modelnya, melainkan standarnya.

# Dipetakan dari 13 pembanding: kombinasi ini belum ditemukan di tempat lain

**1**

## Layanan resmi Indonesia — berhenti di nomor & rekening

cekrekening.id, aduannomor.id, IASC: cek, lapor, blokir. Isi pesannya tidak dinilai — dan tidak ada kumpulan pesan yang dibuka untuk publik.

**2**

## Aplikasi global — menilai isi, tetapi tertutup

ScamShield, Norton Genie, Scamio bisa menilai isi pesan — dalam Bahasa Inggris; data latih dan cara menilainya tidak dibuka.

**3**

## Proyek ini — isi pesan Indonesia, terbuka, label manusia

Vonis isi pesan Bahasa Indonesia dalam bahasa warga + laporan warga + label hanya manusia + kumpulan pesan terbuka + gerbang uji yang dikunci di muka — kegagalannya ikut dipublikasikan.

**Lima unsur itu tidak ditemukan berkumpul di satu pun dari 13 pembanding.**

Pemetaan riset terbuka, Oktober 2026. “Belum ditemukan” dibaca apa adanya: tidak ditemukan pada pembanding yang diperiksa — bukan bukti tidak ada di mana pun.

# Setelah kritik eksternal — yang berubah

Laporan edisi pertama dikritik reviewer eksternal. Kritiknya benar. Ini tindak lanjutnya — app kini v6.1:

**1**

## Vonis tiga status

Berbasis selang kepercayaan Wilson 95% (Laporan Edisi v3.3): Tahap 2C tidak meyakinkan; Tahap 2D — SAH lolos jelas, SMISHING & AUTO-CLOSE gagal jelas. Vonis akhir tidak berubah: klaim 9/10 tetap ditolak.

**2**

## Label warga dilunakkan

Skor model saja kini berbunyi POLANYA SANGAT MIRIP PENIPUAN; label tegas hanya bila aturan keras terpicu, plus peringatan untuk pesan berformat resmi.

**3**

## Privasi & retensi tertulis — UU PDP

Kebijakan privasi & retensi sesuai UU PDP kini tertulis di tab Lapor: gambar tangkapan layar tidak disimpan (OCR diproses di memori); hak hapus dijelaskan apa adanya.

**4**

## Protokol Hakim & Korpus v1

Set hakim independen disegel sampai gerbang berikutnya; kesepakatan antar-penilai (kappa) dipantau selama pengumpulan korpus.

**5**

## App jauh lebih cepat

Waktu siap 41,6 → 7,2 detik — mesin model kini dibangun saat analisis pertama, bukan saat halaman dimuat.

# Coba layanannya.

Sudah coba? Ikut melapor — dan bagikan Galeri Modusnya ke keluarga.

| | |
|---|---|
| aplikasi live | **fraud-triage-demo.streamlit.app** |
| github | **github.com/rwnliwan/fraud-triage** |
| hugging face | **huggingface.co/rwnliwan/fraud-triage-smishing** |

Kumpulan pesan penipuan Indonesia yang publik selama ini kosong — setiap laporan yang diperiksa manusia mengisinya, dan setiap Galeri Modus yang dibagikan melindungi warga berikutnya.

Laporan teknis lengkap — model, data, tahapan, perlakuan, evaluasi — tersedia sebagai dokumen terpisah.

Dibangun dengan bantuan AI sebagai pair engineer; arsitektur, gerbang evaluasi, dan setiap keputusan & pemeriksaan akhir oleh Septian.