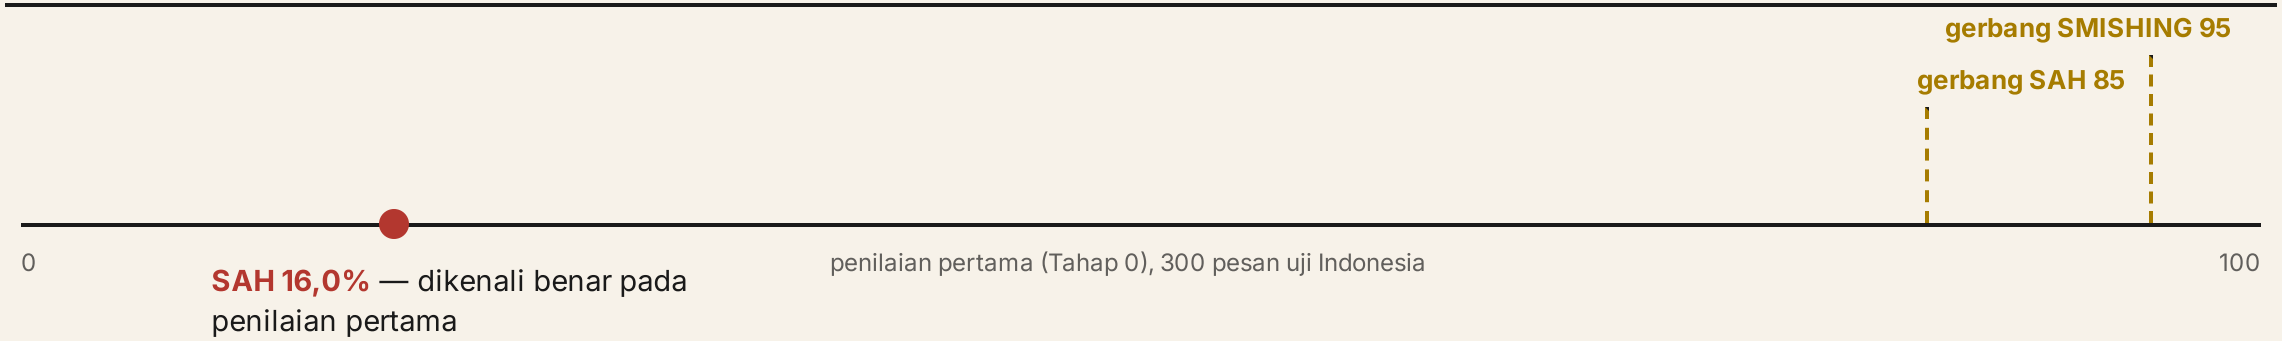
Fraud Triage — proyek penyaringan pesan penipuan (smishing)

SMS ini dari bank beneran — atau penipu?

AI saya salah menebak 84 dari 100 pesan resmi Indonesia.

Kegagalannya didokumentasikan apa adanya — lalu diubah jadi layanan. **Siskamling Digital**: warga cek & lapor pesan penipuan, dan setiap laporan yang diperiksa manusia membangun kumpulan contoh pesan penipuan (korpus). Kumpulan itu selama ini tidak ada.



01

bagian pertama

Riset

Sebuah model dilatih di data Inggris, diuji pada pesan Indonesia, dan syarat lulusnya dikunci di muka — sebelum hasilnya dilihat.

---

a Masalah & latar belakang **b** Pendekatan, data & model **c** Perjalanan & vonis **d** Aplikasi & batasan

Model Inggris yang hebat di kertas, runtuh di pesan Indonesia

16%

Hanya segitu pesan **SAH** Indonesia yang dikenali benar di Tahap 0 — dinilai pada 300 pesan uji (set hakim) yang tidak pernah dipakai melatih model.

84 dari 100 pesan resmi ikut diteruskan ke pemeriksaan manusia. Pesan yang terdengar resmi justru terbaca mencurigakan — gaya bahasa resmi Indonesia tidak pernah ada di data latih Inggris ±2011.

Penipuan SMS itu masalah publik — bukan sekadar masalah model

1 Modusnya menyamar jadi institusi resmi

Pesan penipuan datang sebagai bank, kurir, telco, sampai instansi pemerintah. Korbannya lintas usia — dan kerugiannya bisa terjadi dalam satu klik.

2 Data pembandingnya tertutup

Data penipuan di regulator & industri tidak dibuka. Riset data proyek ini hanya menemukan kumpulan pesan 3-kelas 1.143 baris (±2012–2016) — terlalu tua & kecil; kumpulan pesan berlabel manusia yang publik = 0.

3 Lensa pencegahan: mencegah lebih murah

Dari latar kesehatan masyarakat: menangani korban selalu lebih mahal daripada mencegahnya. Layanan ini dibangun sebagai pencegahan, bukan pemadam kebakaran.

4 Siskamling: ronda warga, versi digital

Namanya dari ronda malam — warga jaga bersama, lapor bersama. Itulah asal nama Siskamling Digital: keamanan sebagai kerja bersama, bukan urusan korban sendirian.

Maka kekosongan itu diisi oleh warga sendiri — lewat laporan mereka.

Tiga lapis: skor, ambang, aturan

1 Gabungan tiga model (ensemble)

Satu model bahasa (DistilBERT) + dua model statistik kata (TF-IDF / Logistic Regression). Skornya adalah peringkat penyaringan — bukan vonis.

2 Dua ambang keputusan

Ambang bawah 0,010 — di bawahnya kasus ditutup otomatis. Ambang atas 0,135 — di atasnya langsung diteruskan. Di antaranya: manusia yang memeriksa.

3 Lapisan aturan S1–S3 + sinyal penenang

Sinyal keras hanya menaikkan tingkat keputusan. Sinyal penenang resmi boleh menurunkannya tepat satu tingkat — dan gugur bila ada sinyal kuat.

Model dilatih pada SMS Inggris ±2011 — dan dinilai pada 300 pesan Indonesia yang belum pernah dilihatnya

1

Data latih babak seleksi

Kumpulan pesan spam/penipuan Bahasa Inggris publik (era ±2011).

2

Pesan uji (set hakim) Indonesia

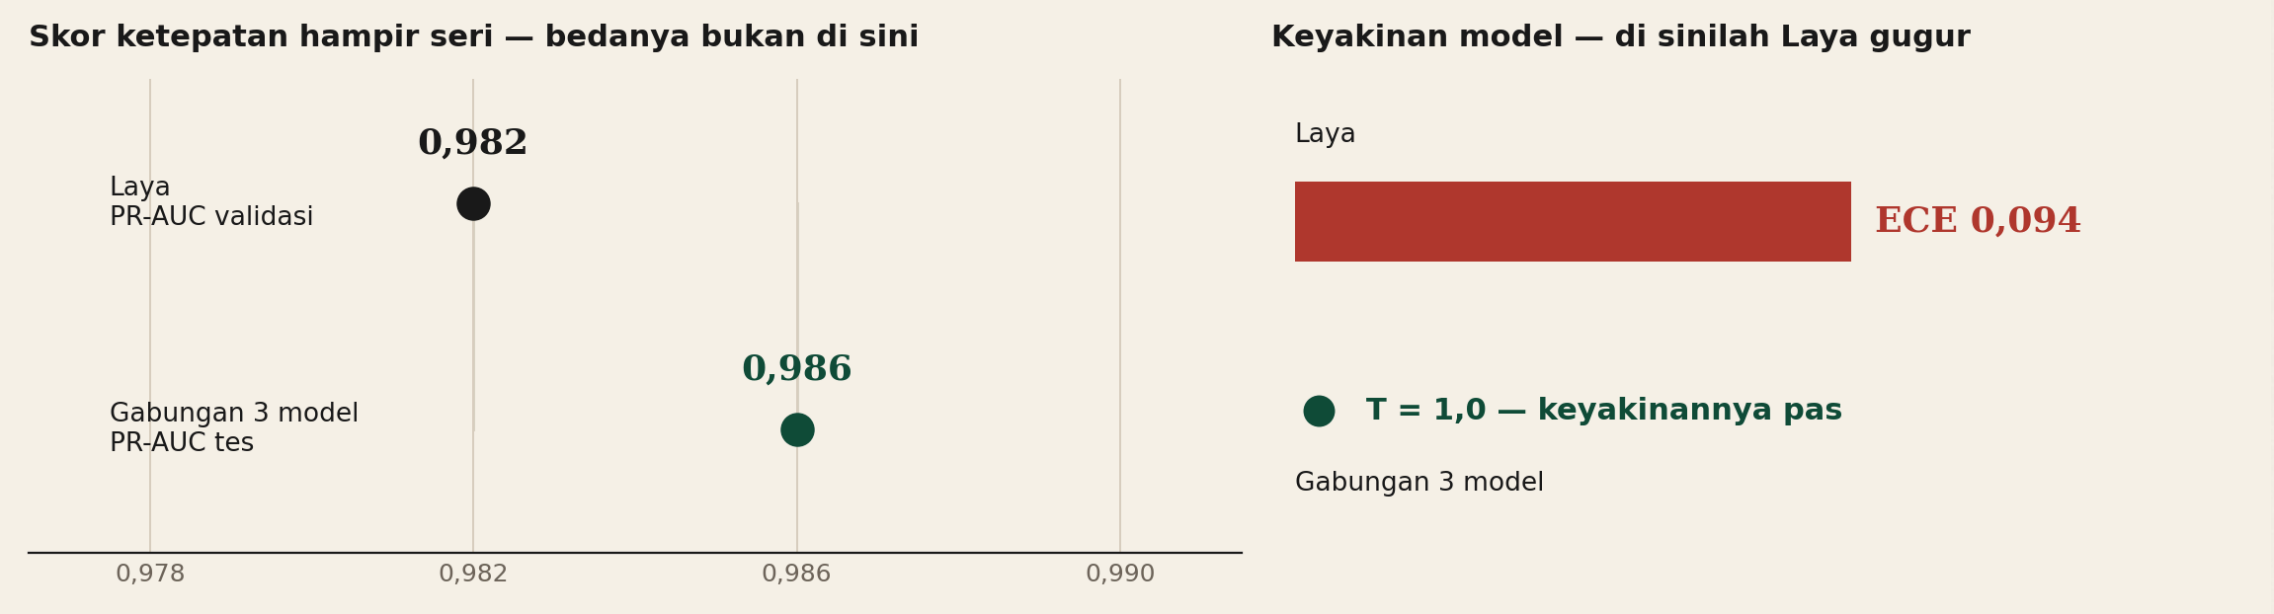
300 pesan, TIDAK pernah jadi data latih — khusus menguji klaim.

3

Hasil riset data Indonesia

Kumpulan pesan 3-kelas 1.143 baris (±2012–2016, terlalu tua/kecil), data regulator tertutup → kesimpulan: kumpulan pesan penipuan Indonesia berlabel manusia yang publik = 0.

Dua kandidat akhir, skornya seri — angka keyakinannya yang membedakan



Gambar 1 — Dua kandidat akhir: skor ketepatannya (PR-AUC) hampir seri — yang membedakan, seberapa bisa dipercaya angka keyakinannya.

Laya — model bahasa (BERT) yang dilatih ulang. Angka keyakinannya meleset jauh (ECE 0,094) dan lambat (2,81 detik/pesan). ● **GUGUR**

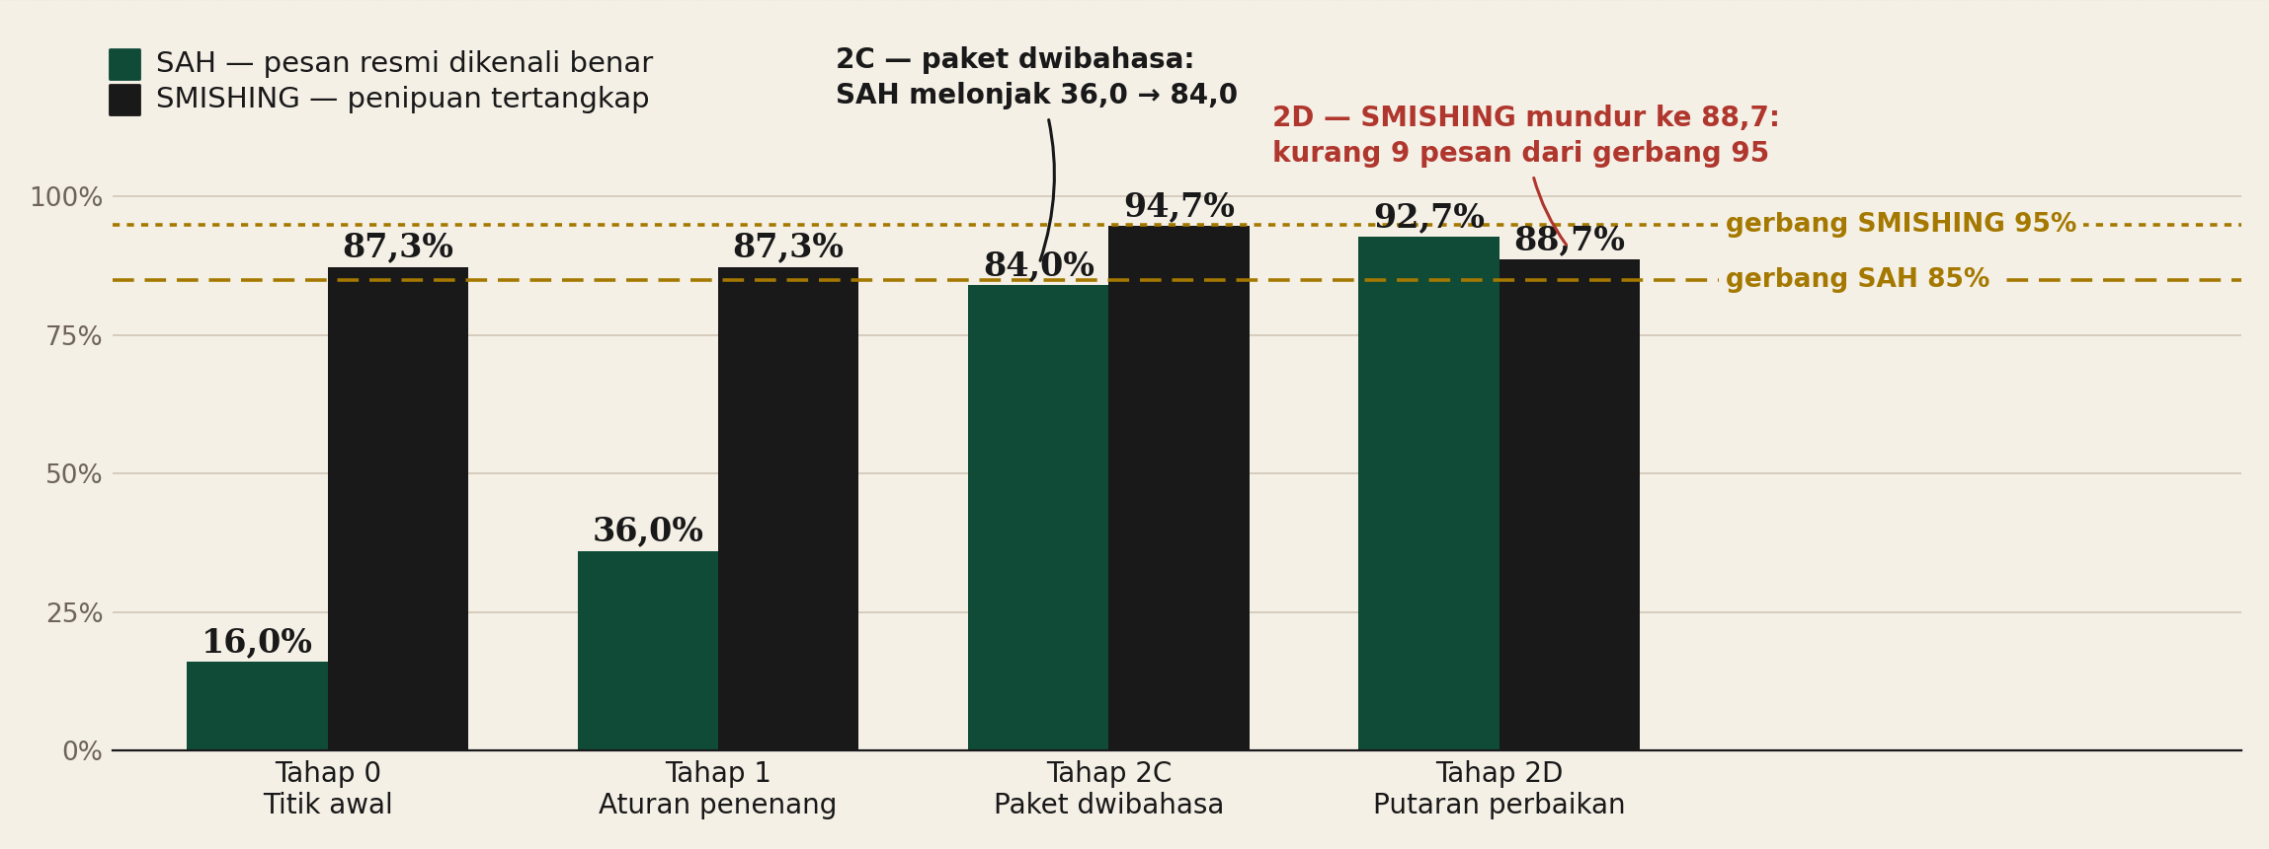
Gabungan tiga model. Keyakinannya terpercaya (T = 1,0), cepat — tetap model aplikasi sampai hari ini. ● **TERPILIH (CHOSEN)**

babak seleksi
6 kandidat model diuji pada kumpulan pesan Inggris yang sama.

finalis
Laya vs gabungan tiga model — dua yang tersisa di ujung seleksi.

penentu
Bukan skor tertinggi di satu ukuran — yang keyakinannya bisa dipercaya & layak operasi.

SAH naik 16% → 92,7% — SMISHING justru mundur di langkah terakhir



Gambar 2 — Setiap tahap dinilai sebagai satu paket utuh pada pesan uji yang sama. Garis kuning = syarat lulus (gerbang) yang dikunci sebelum percobaan dimulai.

Klaim 9/10: gagal 2 dari 4 gerbang

92,7%

SAH

Gerbang ≥ 85% — pesan resmi dikenali benar

88,7%

SMISHING

Gerbang ≥ 95% — kurang 9 pesan dari target

2

Smishing tertutup otomatis (AUTO-CLOSE)

Gerbang = 0 — penipuan yang tertutup otomatis tanpa dilihat manusia

0,9882

Skor ketepatan (PR-AUC) pada data Inggris

Gerbang ≥ 0,98 — kemampuan pada data Inggris tidak rusak

Total akhir Tahap 2D: **90,7%** · panel uji **16/16** — dan klaimnya tetap gagal 2 dari 4 gerbang.

Model di aplikasi tidak ditukar. Kegagalannya didokumentasikan apa adanya — bukan digeser ambangnya sampai terlihat lolos.

Gagalnya mendasar: datanya memang tidak ada

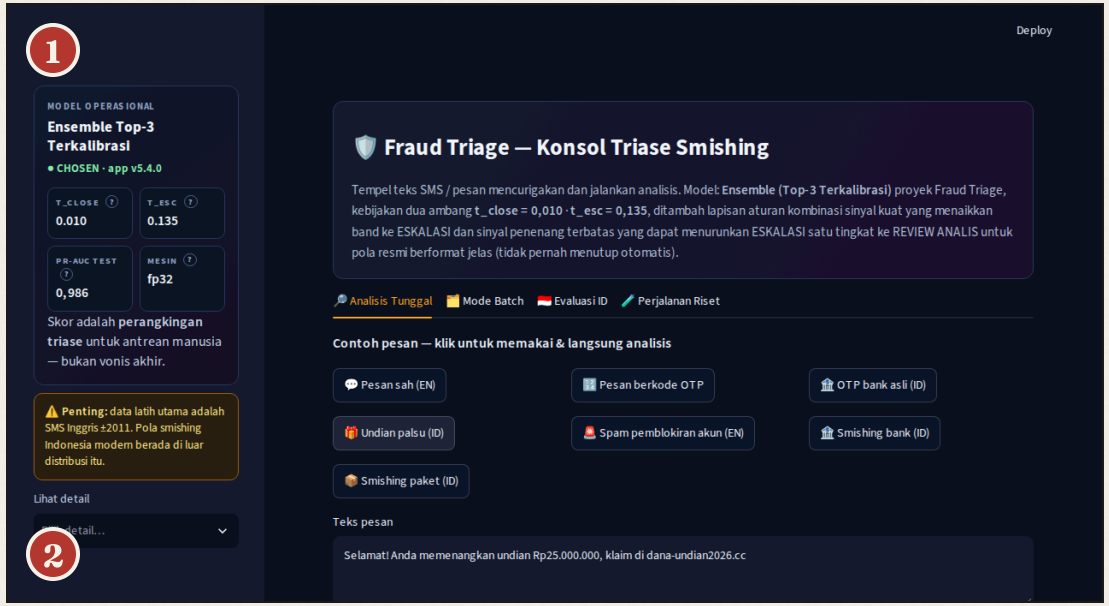
0

Kumpulan pesan penipuan (smishing) Indonesia yang publik dan bisa dipakai: nol.

Yang tersisa hanya kumpulan pesan SMS 3-kelas berisi 1.143 baris dari era ±2012–2016. Data regulator dan operator ada — tetapi tertutup.

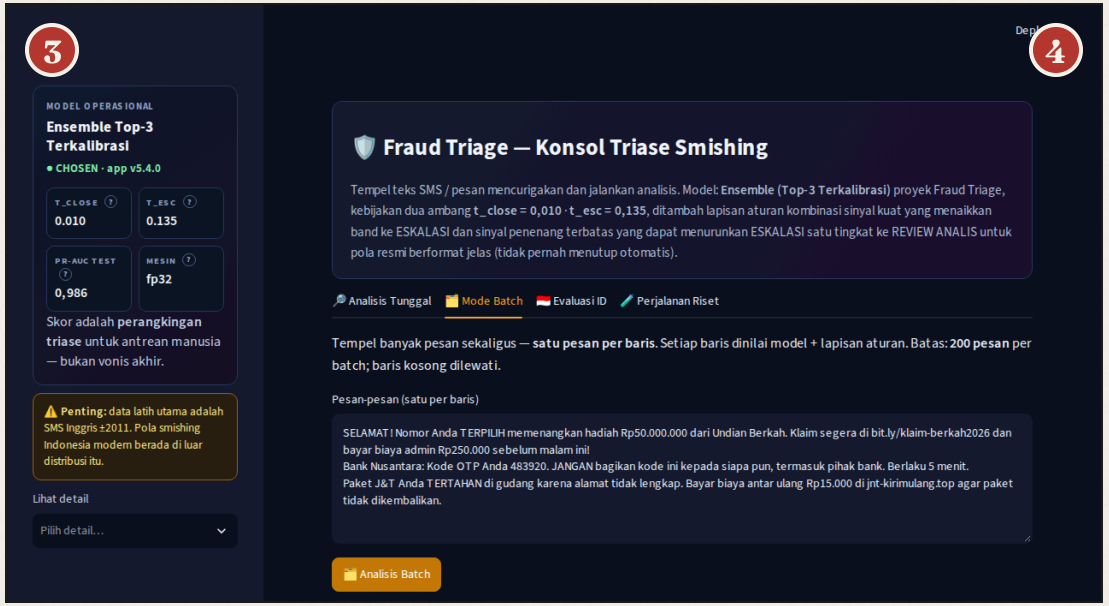
Sebagian besar kumpulan pesan latih proyek ini akhirnya harus dibangun sendiri: 2.512 baris, sudah diperiksa agar tidak bocor ke pesan uji.

Dua mode, satu prinsip: transparan di muka, manusia yang memutuskan



Gambar 3a — Analisis Tunggal. 1 kartu tingkat keputusan tampil di muka · 2 daftar sinyal: alasan skor terbaca satu per satu.

Skor yang bisa dipercaya — angka yang sama dipakai untuk mengurutkan antrean.



Gambar 3b — Mode Batch. 3 antrean ratusan pesan terurut prioritas risiko · 4 detail per kasus dibuka analis sebelum memutuskan.

Laporan kasus — hasil penyaringan bisa diunduh per kasus.

Dipakai warga, dibangun warga, melindungi warga

1 Warga

Cek pesan sebelum klik — vonis dalam bahasa awam plus langkah tindakannya. Yang mencurigakan, laporkan sekalian: satu laporan bisa melindungi warga berikutnya.

2 Komunitas

Galeri Modus: modus-modus dari laporan nyata warga, terkelompok per kategori — edukasi yang hidup dari kejadian sebenarnya.

3 Kumpulan pesan

Setiap laporan yang diperiksa & dilabeli manusia masuk kumpulan pesan publik yang selama ini tidak ada — bahan latih model Indonesia berikutnya.

4 Analis

Konsol pemilahan memilah pola laporan yang masuk: mesin menyaring & memberi saran, label akhir selalu manusia.

Lapor → Diperiksa manusia → Kumpulan pesan tumbuh → Model membaik → Warga lebih terlindungi

Bukan sekadar alat cek — kumpulan pesan penipuan Indonesia dari laporan warga, diperiksa & dilabeli manusia.

Tiga batasan yang tidak disembunyikan

1 Data latih Inggris ±2011

Fondasi modelnya tua dan berbahasa lain. Kumpulan pesan Indonesia dibangun sendiri — dan tetap kecil.

2 Pesan uji (set hakim) sudah terbakar

300 pesan penilai yang sama dipakai berulang — untuk iterasi berikutnya, ia tidak lagi netral. Set hakim baru wajib dibuat.

3 Antrean manusia tetap pengikat

Di Tahap 2D, pesan SAH yang berhenti di tahap periksa (REVIEW) naik 23 → 47. Di volume besar, kapasitas analis — bukan model — yang menentukan.

02

bagian kedua

Layanan

Temuan risetnya berubah menjadi Siskamling Digital — layanan publik cek & lapor yang membangun kumpulan pesan yang tidak ada itu, laporan demi laporan dari warga.

---

a Misi & warga **b** Mesin menyaring, manusia memutuskan **c** Pengamanan & linimasa versi **d** Status jujur & pembeda

Dari riset ke layanan: kumpulan pesan yang tidak ada, dibangun dari warga

→

Temuan proyek

Kumpulan pesan penipuan (smishing) Bahasa Indonesia berlabel manusia belum ada yang publik. Itulah akar gagalnya model — dan celah yang bisa ditutup warga sendiri.

→

Misinya berubah

Layanan publik untuk cek & lapor pesan mencurigakan — yang sekalian membangun kumpulan pesan itu, laporan demi laporan, dengan izin pelapornya.

→

Siskamling Digital — sudah tayang

Nama lolos cek bentrok merek (DJKI). Ronda kampung, versi digital: warga saling menjaga dari penipuan pesan. fraud-triage-demo.streamlit.app

Untuk warga: cek dulu, sebelum klik

1 Cek — vonis dalam bahasa awam

Tempel pesan, dapat vonis: 🔴 Polanya sangat mirip penipuan · 🟡 Mencurigakan · 🟢 Risiko rendah — lengkap dengan kartu langkah darurat sesuai keadaan, termasuk tautan resmi IASC OJK, cekrekening.id, dan aduannomor.id.

2 Lapor — pribadi dibersihkan otomatis

Laporan bisa ditempel sebagai teks, atau teksnya dibaca otomatis dari tangkapan layar. Isinya dibersihkan dari data pribadi sebelum disimpan; pengirim hanya disimpan sebagai kode samaran satu arah. Setiap laporan menerima kode lacak untuk mengecek status pemeriksaannya.

3 Galeri Modus — kenali polanya dulu

Modus yang sudah diperiksa, bisa disaring per kategori, supaya warga mengenali pola penipuan sebelum menjadi korban.

Mesin menyaring, manusia memutuskan.

1 Bersihkan data pribadi

Data pribadi dibersihkan dari teks laporan sebelum apa pun disimpan.

2 Samarkan pengirim

Pengirim disimpan hanya sebagai kode samaran satu arah — tidak bisa dikembalikan menjadi nomor aslinya.

3 Saran mesin

Model memberi saran label untuk mempercepat antrean pemeriksaan.

4 Label akhir: selalu manusia

Lewat gerbang kata sandi admin. Model yang melabeli data latihnya sendiri itu berputar-putar — hasilnya tidak akan pernah netral.

Satu-satunya pintu masuk kumpulan pesan: hanya laporan yang sudah diperiksa, disetujui pelapornya, dan dilabeli manusia.

Dibangun untuk publik beneran, bukan demo sekali pakai

1 Batas jumlah & anti-duplikat

Maksimum 10 laporan per pengirim per hari dan 300 per hari secara keseluruhan. Laporan duplikat terdeteksi dan tidak menggandakan antrean.

2 Pemutus & tombol darurat

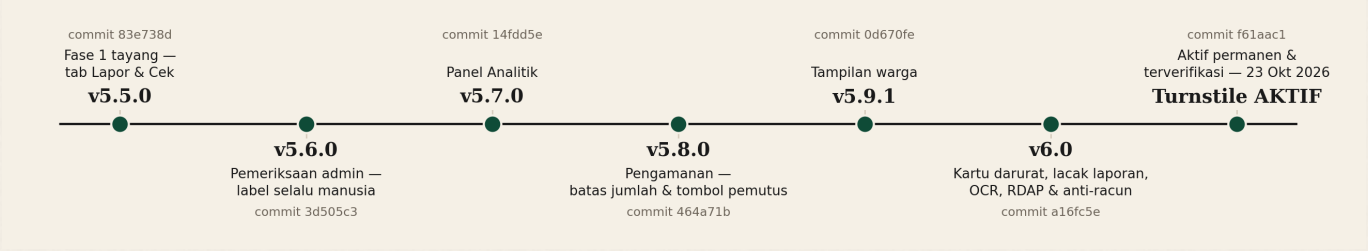
Antrean menunggu yang membengkak memutus penerimaan laporan. Penerimaan bisa ditutup manual kapan saja dari tab Verifikasi.

3 Monitor lonjakan & cadangan

Lonjakan ≥100 laporan per jam menutup penerimaan laporan otomatis dan memberi kabar. Cadangan kumpulan pesannya disimpan tiap minggu.

4 Tampilan warga & pemeriksa bot

Tab Lapor tampil pertama, dengan ajakan “Cek dulu, sebelum klik.” Pemeriksa bot Cloudflare (Turnstile) aktif permanen sejak 23 Oktober 2026, terverifikasi di perangkat asli.



Gambar 4 — Linimasa versi layanan: dari Fase 1 (v5.5.0) sampai v6.0 & Turnstile aktif, lengkap dengan kode versinya (commit) — ditutup 23 Oktober 2026 dengan Turnstile aktif permanen, terverifikasi di perangkat asli.

Status jujur: kumpulan pesannya mulai dari nol, hari ini

0

Label di kumpulan pesan saat peluncuran. Pengumpulan dimulai sekarang — bukan angka yang diklaim sudah ada.

±1.000

Target label berlabel manusia. Setiap label lewat pemeriksaan admin, bukan label otomatis.

Fase 4

Latih ulang hanya dengan pesan uji baru — dan syarat lulusnya dikunci di muka, sebelum hasil dilihat.

Tidak ada latih ulang diam-diam di tengah jalan: kumpulan pesan tumbuh dulu, pesan ujinya baru, syarat lulusnya terkunci — urutannya tidak ditukar.

Satu opsi terbuka di Tahap 3: model khusus Indonesia — termasuk rilis terbaru saat itu — diuji ulang secara setara di arena yang sama. Yang dipertahankan bukan modelnya, melainkan standarnya.

Dipetakan dari 13 pembanding: kombinasi ini belum ditemukan di tempat lain

1

Layanan resmi Indonesia — berhenti di nomor & rekening

cekrekening.id, aduannomor.id, IASC: cek, lapor, blokir. Isi pesannya tidak dinilai — dan tidak ada kumpulan pesan yang dibuka untuk publik.

2

Aplikasi global — menilai isi, tetapi tertutup

ScamShield, Norton Genie, Scamio bisa menilai isi pesan — dalam Bahasa Inggris; data latih dan cara menilainya tidak dibuka.

3

Proyek ini — isi pesan Indonesia, terbuka, label manusia

Vonis isi pesan Bahasa Indonesia dalam bahasa warga + laporan warga + label hanya manusia + kumpulan pesan terbuka + gerbang uji yang dikunci di muka — kegagalannya ikut dipublikasikan.

Lima unsur itu tidak ditemukan berkumpul di satu pun dari 13 pembanding.

Pemetaan riset terbuka, Oktober 2026. “Belum ditemukan” dibaca apa adanya: tidak ditemukan pada pembanding yang diperiksa — bukan bukti tidak ada di mana pun.

Setelah kritik eksternal — yang berubah

Laporan edisi pertama dikritik reviewer eksternal. Kritiknya benar. Ini tindak lanjutnya — app kini v6.1:

1

Vonis tiga status

Berbasis selang kepercayaan Wilson 95% (Laporan Edisi v3.3): Tahap 2C tidak meyakinkan; Tahap 2D — SAH lolos jelas, SMISHING & AUTO-CLOSE gagal jelas. Vonis akhir tidak berubah: klaim 9/10 tetap ditolak.

2

Label warga dilunakkan

Skor model saja kini berbunyi POLANYA SANGAT MIRIP PENIPUAN; label tegas hanya bila aturan keras terpicu, plus peringatan untuk pesan berformat resmi.

3

Privasi & retensi tertulis — UU PDP

Kebijakan privasi & retensi sesuai UU PDP kini tertulis di tab Lapor: gambar tangkapan layar tidak disimpan (OCR diproses di memori); hak hapus dijelaskan apa adanya.

4

Protokol Hakim & Korpus v1

Set hakim independen disegel sampai gerbang berikutnya; kesepakatan antar-penilai (kappa) dipantau selama pengumpulan korpus.

5

App jauh lebih cepat

Waktu siap 41,6 → 7,2 detik — mesin model kini dibangun saat analisis pertama, bukan saat halaman dimuat.

Coba layanannya.

Sudah coba? Ikut melapor — dan bagikan Galeri Modusnya ke keluarga.

aplikasi live	**fraud-triage-demo.streamlit.app**
github	**github.com/rwnliwan/fraud-triage**
hugging face	**huggingface.co/rwnliwan/fraud-triage-smishing**

Kumpulan pesan penipuan Indonesia yang publik selama ini kosong — setiap laporan yang diperiksa manusia mengisinya, dan setiap Galeri Modus yang dibagikan melindungi warga berikutnya.

Laporan teknis lengkap — model, data, tahapan, perlakuan, evaluasi — tersedia sebagai dokumen terpisah.

Dibangun dengan bantuan AI sebagai pair engineer; arsitektur, gerbang evaluasi, dan setiap keputusan & pemeriksaan akhir oleh Septian.